

UNIVERSIDAD DE COSTA RICA
SISTEMA DE ESTUDIOS DE POSGRADO

APRENDIZAJE AUTOMÁTICO MULTIMODAL PARA LA PREDICCIÓN DE
RIESGO DE OSTEOPOROSIS

Propuesta de tesis

CARLOS BENAVIDES VÍQUEZ

Ciudad Universitaria Rodrigo Facio, Costa Rica

This thesis proposal was approved by the Assessor Committee, as a partial requirement to opt for the Academic Master's degree in Electrical Engineering.

Este anteproyecto fue aceptado por el Comité Asesor, como requisito parcial para optar por el grado de Maestría Académica en Ingeniería Eléctrica.

Dr. rer. nat. Francisco Siles Canales
Thesis Director

[TBD]
Thesis Assessor

[TBD]
Thesis Assessor

Carlos Benavides Víquez
Candidate

Tabla de contenido

Lista de tablas	v
Tabla de figuras	vi
Glosario	vii
Acronimos	x
1 Introducción	1
1.1. Antecedentes y motivación	1
1.2. Organización del documento	2
1.3. Literatura profesional	3
1.4. Descripción del problema	7
1.5. Hipótesis	8
1.6. Objetivos	9
1.7. Alcance y limitaciones	9
2 Marco teórico	11
2.1. Densitometría ósea, diagnóstico de la osteoporosis y modalidades DXA	11
2.2. Aprendizaje automático para clasificación transversal	15
2.3. Métricas de evaluación	17
2.4. Interpretabilidad de modelos y valores SHAP	18
3 Metodología	20
3.1. Diseño de la investigación	20
3.2. Fase 1: Consolidación y preprocesamiento (<i>ETL</i>)	20
3.3. Fase 2: Integración multimodal y manejo de desbalance	22
3.4. Fase 3: Desarrollo de modelos de clasificación transversal	24
3.5. Fase 4: Validación estadística e interpretabilidad	25
3.6. Cronograma de trabajo	26
4 Resultados preliminares y análisis	28

4.1. Estado de la consolidación de la base de datos (<i>ETL</i>)	28
4.2. Estadísticas descriptivas de la cohorte CIMOHU	29
4.3. Auditoría de calidad de datos por modalidad	30
4.4. Experimento piloto: regresión logística de línea base	32
4.5. Análisis de ablación de rescate: aporte de la composición corporal (Piloto B')	34
4.6. Discusión de los resultados preliminares	36
Bibliografía	38
Apendice A Clasificación de métodos de predicción	44
Apendice B Distribución temporal de la literatura profesional	45

Lista de tablas

4.1. Estado de consolidación de los respaldos de la base de datos CIMOHU	28
4.2. Características demográficas y clínicas de la cohorte etiquetada CIMOHU	30
4.3. Auditoría de calidad de datos por modalidad y variable	31
4.4. Resultados del experimento piloto de regresión logística	33
4.5. Análisis de ablación de rescate (Piloto B')	35
A.1. Clasificación de la literatura principal de clasificación transversal de osteoporosis según el tipo de datos de entrada.	44

Tabla de figuras

2.1. Diagrama conceptual de la integración multimodal propuesta	15
3.1. <i>Pipeline</i> metodológico de cuatro fases	20
4.1. Escala y composición de la base de datos DXA del CIMOHU	29
B.1. Distribución anual de la literatura profesional revisada	45

Glosario

Absorciometría de Rayos X de Energía Dual (DXA)

Técnica de imagen de baja dosis radiactiva que mide la Densidad Mineral Ósea (DMO) y la composición corporal a partir de la atenuación diferencial de dos haces de rayos X con distinta energía. Es el estándar de oro para el diagnóstico de osteoporosis según los criterios de la OMS (1994).

Análisis Estructural de Cadera (HSA)

Conjunto de métricas geométricas derivadas del escaneo DXA que caracterizan la resistencia biomecánica del cuello femoral: Área de Sección Transversal (CSA), Índice de Sección de Módulo Compuesto (CSMI), Longitud del Eje de la Cadera (HAL) y ancho cortical. Permite estimar la fragilidad estructural de forma independiente a la DMO puntual.

Densidad Mineral Ósea (DMO / BMD)

Masa de mineral óseo por unidad de área proyectada (g/cm^2), estimada por DXA en sitios esqueléticos de interés clínico: cuello femoral, cadera total y columna lumbar (L1–L4). Es la variable primaria sobre la que se calculan el T-score y el Z-score diagnósticos.

Evaluación de Fractura Vertebral (VFA)

Modalidad del DXA que genera una imagen lateral de la columna dorso-lumbar (T6–L4) con dosis de radiación mínima, permitiendo la detección semicuantitativa de deformidades vertebrales y micro-fracturas silenciosas mediante la clasificación de Genant (1993).

Fractura por fragilidad

Fractura producida por un mecanismo de baja energía, equivalente a una caída desde la propia altura o por esfuerzo mínimo. Es indicativa de fragilidad esquelética subyacente y constituye el desenlace clínico primario que los modelos de riesgo buscan predecir.

FRAX	Herramienta de cálculo probabilístico desarrollada por la Universidad de Sheffield (Kanis et al.) que combina la DMO del cuello femoral con once factores clínicos para estimar la probabilidad absoluta de fractura mayor osteoporótica y de fractura de cadera a 10 años. Se calibra por país a partir de datos de epidemiología de fracturas y mortalidad locales.
Modelo multimodal	Modelo predictivo que integra simultáneamente variables de distinta naturaleza o fuente (p.ej. DMO + HSA + VFA + composición corporal + datos clínicos tabulares), en lugar de basarse en una única señal. La fusión de modalidades permite capturar interacciones que ningún marcador individual puede reflejar por sí solo.
Osteosarcopenia	Condición musculoesquelética sinérgica definida por la coexistencia de baja masa ósea (osteopenia/osteoporosis) y sarcopenia. Implica un riesgo de caídas y fracturas amplificado respecto al de cada condición por separado, y puede estar presente aun cuando el T-score aislado se sitúe en rango normal.
<i>Pipeline</i> metodológico	Secuencia estructurada de etapas de procesamiento de datos y modelado, desde la ingesta y curación de la fuente de datos hasta la generación de un reporte interpretable para el clínico. En esta investigación: ETL → Integración multimodal → Modelo transversal → Interpretabilidad → Validación.
SHAP (<i>SHapley Additive exPlanations</i>)	Marco de interpretabilidad basado en la teoría de juegos cooperativos (valores de Shapley) que asigna a cada variable predictora una contribución marginal cuantificada a la predicción individual del modelo. Garantiza tres propiedades axiomáticas: precisión local (la suma de contribuciones individuales iguala la predicción del modelo), <i>missingness</i> (variables ausentes reciben contribución cero) y consistencia (si una variable contribuye más bajo cualquier coalición posible, su valor SHAP no disminuye).
T-score	Número de desviaciones estándar en las que la DMO de un paciente se aleja de la media de una población adulta joven y sana de referencia, medida en

el mismo sitio esquelético con el mismo tipo de equipo. Criterio diagnóstico OMS: $\leq -2,5$ osteoporosis; entre $-2,5$ y $-1,0$ osteopenia; $\geq -1,0$ normal.

Z-score

Número de desviaciones estándar en las que la DMO de un paciente se aleja de la media de individuos de su misma edad, sexo y grupo étnico de referencia. A diferencia del T-score, contextualiza la pérdida ósea respecto al envejecimiento esperado y es de utilidad clínica preferente en pacientes premenopáusicas y adultos menores de 50 años.

Acrónimos

AUC	Área Bajo la Curva ROC (<i>Area Under the ROC Curve</i>)
BMC	Contenido Mineral Óseo (<i>Bone Mineral Content</i>)
BMD	Densidad Mineral Ósea (<i>Bone Mineral Density</i>)
CCSS	Caja Costarricense de Seguro Social
CIMOHU	Centro de Investigación en Movimiento Humano, Universidad de Costa Rica
CNN	Red Neuronal Convolucional (<i>Convolutional Neural Network</i>)
CSA	Área de Sección Transversal (<i>Cross-Sectional Area</i>)
CSMI	Índice de Sección de Módulo Compuesto (<i>Cross-Sectional Moment of Inertia</i>)
DL	Aprendizaje Profundo (<i>Deep Learning</i>)
DMO	Densidad Mineral Ósea (véase BMD)
DXA	Absorciometría de Rayos X de Energía Dual (<i>Dual-energy X-ray Absorptiometry</i>)
EHR	Historia Clínica Electrónica (<i>Electronic Health Record</i>)
ETL	Extracción, Transformación y Carga (<i>Extract, Transform, Load</i>)
FRAX	Herramienta de Evaluación del Riesgo de Fractura (<i>Fracture Risk Assessment Tool</i>)
HAL	Longitud del Eje de la Cadera (<i>Hip Axis Length</i>)
HSA	Análisis Estructural de Cadera (<i>Hip Structural Analysis</i>)
IC	Intervalo de Confianza
IMC	Índice de Masa Corporal
LightGBM	Potenciación de Gradiente Ligera (<i>Light Gradient Boosting Machine</i>)

LMIC	Países de Ingresos Medios y Bajos (<i>Low- and Middle-Income Countries</i>)
MAE	Error Absoluto Medio (<i>Mean Absolute Error</i>)
MCC	Coefficiente de Correlación de Matthews (<i>Matthews Correlation Coefficient</i>)
ML	Aprendizaje Automático (<i>Machine Learning</i>)
MLP	Perceptrón Multicapa (<i>Multilayer Perceptron</i>)
NHANES	Encuesta Nacional de Salud y Nutrición de EE.UU. (<i>National Health and Nutrition Examination Survey</i>)
OMS	Organización Mundial de la Salud
OR	Razón de Momios (<i>Odds Ratio</i>)
ORAI	Instrumento de Evaluación de Riesgo de Osteoporosis (<i>Osteoporosis Risk Assessment Instrument</i>)
OST	Herramienta de Autodiagnóstico de Osteoporosis (<i>Osteoporosis Self-Assessment Tool</i>)
RBF	Función de Base Radial (<i>Radial Basis Function</i>)
RF	Bosque Aleatorio (<i>Random Forest</i>)
ROC	Característica Operativa del Receptor (<i>Receiver Operating Characteristic</i>)
SHAP	Valores de Shapley Aditivos Explicativos (<i>SHapley Additive exPlanations</i>)
SMOTE	Técnica de Sobremuestreo de la Minoría Sintética (<i>Synthetic Minority Over-sampling Technique</i>)
SVM	Máquinas de Vectores de Soporte (<i>Support Vector Machines</i>)
VFA	Evaluación de Fractura Vertebral (<i>Vertebral Fracture Assessment</i>)
XGBoost	Potenciación de Gradiente Extrema (<i>eXtreme Gradient Boosting</i>)

Capítulo 1

Introducción

Este capítulo presenta el contexto clínico y científico que motiva la presente investigación, establece el estado de la literatura relevante, define el problema de investigación con sus preguntas de investigación asociadas, plantea la hipótesis de trabajo, establece los objetivos y el alcance del estudio.

1.1. Antecedentes y motivación

La osteoporosis constituye uno de los mayores desafíos de salud pública a nivel global debido a su asociación directa con las fracturas por fragilidad. La carga epidemiológica y económica de esta enfermedad es considerable: se estiman más de 200 millones de personas afectadas en el mundo [1], con 3,5 millones de fracturas nuevas registradas únicamente en la Unión Europea durante 2010, a un costo superior a los 37 mil millones de euros [2].

Las consecuencias de estas fracturas —en particular las de cadera— van más allá del dolor y la limitación funcional, asociándose con tasas de mortalidad del 15 al 36 % durante el primer año tras el evento, así como con discapacidad prolongada y un deterioro severo de la calidad de vida [2, 3].

En el plano regional, Medina et al. [4] documentaron que la carga de osteoporosis y fracturas por fragilidad en América Latina ha aumentado significativamente en la última década, con tasas de fractura de cadera que oscilan entre 63 y 276,2 por 100.000 habitantes según el país, subrayando la urgencia de modelos diagnósticos adaptados a la realidad latinoamericana.

En Costa Rica, este fenómeno adquiere una urgencia creciente: las proyecciones demográficas indican que el 25 % de la población superará los 65 años para 2050 [5], lo que anticipa un aumento sostenido en la prevalencia de enfermedades musculoesqueléticas relacionadas con el envejecimiento. Un estudio reciente en mujeres posmenopáusicas costarricenses atendidas en la Caja Costarricense de Seguro Social (CCSS) reportó una prevalencia de osteoporosis del 39 % y de osteopenia del 47 %, con la edad, la edad a la menarquia, los años transcurridos desde la menopausia y el antecedente familiar de fractura de cadera como predictores clínicos significativos [6].

Pese a esta realidad, el paradigma diagnóstico clínico vigente presenta limitaciones estructurales

importantes. Las herramientas de cribado disponibles —FRAX®, OST y ORAI— han sido calibradas principalmente con cohortes de Europa y América del Norte, lo que puede derivar en clasificaciones erróneas cuando se aplican a otras poblaciones [7]. En este sentido, Moncada-Jiménez et al. [8], utilizando el equipo DXA del Centro de Investigación en Movimiento Humano (CIMO HU) de la Universidad de Costa Rica, documentaron diferencias estadísticamente significativas en la composición corporal entre adultos costarricenses y estadounidenses, subrayando la necesidad de modelos diagnósticos específicos para la población local.

El equipo DXA genera cientos de variables numéricas que abarcan la composición corporal regional (masa grasa, masa magra y masa ósea), parámetros del análisis estructural de cadera (*Hip Structural Analysis*, HSA) y datos de morfometría vertebral. Sin embargo, la práctica clínica habitual descarta la mayor parte de esta información para emitir un diagnóstico basado en uno o dos T-scores. El aprendizaje automático (ML, por sus siglas en inglés) ofrece la posibilidad de integrar estas múltiples modalidades en un modelo predictivo que vaya más allá de la clasificación estática y permita estimar el riesgo individualizado de desarrollo de osteoporosis sin requerir exámenes adicionales, sin irradiación extra y sin costo adicional para el paciente.

El CIMO HU de la UCR cuenta con un activo de datos único: 9.426 exámenes DXA de 3.231 adultos costarricenses con examen registrado (3.240 en la base de datos) entre 2009 y 2026, incluyendo 938 pacientes con dos o más visitas distintas y un seguimiento máximo de 14,15 años. Esta cohorte representa una oportunidad sin precedentes para desarrollar y validar modelos de clasificación multimodal adaptados a la realidad demográfica y clínica del país.

1.2. Organización del documento

El presente documento se organiza de la siguiente manera: el Capítulo 1 —la presente introducción— establece el contexto clínico y científico, revisa la literatura profesional relevante, define el problema de investigación, presenta la hipótesis, los objetivos y el alcance del estudio; el Capítulo 2 desarrolla el marco teórico sobre osteoporosis, la tecnología DXA y los fundamentos de los algoritmos de ML relevantes; el Capítulo 3 describe la metodología de investigación, incluyendo el diseño del estudio, el *pipeline* de datos y el plan de validación estadística; el Capítulo 4 presenta los resultados preliminares y su análisis. Se incluyen además apéndices con material de referencia complementario.

1.3. Literatura profesional

Existen distintos enfoques y algoritmos que han sido desarrollados para estimar el riesgo de osteoporosis, con una evolución que va desde las herramientas clínicas de cribado pre-DXA, pasando por la consolidación de la densitometría ósea como estándar diagnóstico internacional, hasta los modelos de aprendizaje automático multimodales que buscan aprovechar la riqueza de datos que dicho estándar genera pero que la práctica clínica habitualmente descarta. A continuación se revisa la literatura más relevante para establecer el estado del arte y justificar la línea de trabajo propuesta.

Herramientas clínicas de cribado

Las herramientas de cribado clínico más utilizadas a nivel mundial son FRAX®, OST y ORAI. FRAX® es un modelo probabilístico desarrollado en la Universidad de Sheffield bajo el aval de la OMS que estima la probabilidad a 10 años de fractura de cadera y de fractura mayor osteoporótica, integrando la DMO del cuello femoral con hasta once factores de riesgo clínicos [9]. OST (*Osteoporosis Self-Assessment Tool*) y ORAI (*Osteoporosis Risk Assessment Instrument*) son índices más simples basados en variables clínicas de fácil acceso —edad y peso corporal para el OST; edad, peso corporal y antecedente de terapia de reemplazo estrogénico para el ORAI—, diseñados para un cribado rápido sin necesidad de DXA. Si bien estas herramientas han demostrado utilidad en las poblaciones para las que fueron calibradas, reportes recientes —incluyendo la declaración de la ASBMR Task Force de 2024— reconocen que los valores de referencia utilizados provienen de cohortes predominantemente caucásicas y que pueden clasificar erróneamente a poblaciones de otras regiones o grupos raciales y étnicos subrepresentados [7].

DXA como estándar diagnóstico y sus limitaciones

La Organización Mundial de la Salud estableció en 1994 la Absorciometría de Rayos X de Energía Dual (DXA) como el estándar de referencia para el diagnóstico de la osteoporosis, cuantificando la Densidad Mineral Ósea (DMO) mediante el *T-score*: número de desviaciones estándar que separan la DMO del paciente de la media de una población adulta joven y sana [10]. Este criterio —*T-score* $\leq -2,5$ para osteoporosis, entre $-2,5$ y $-1,0$ para osteopenia— se convirtió en el lenguaje universal del diagnóstico óseo y sigue siendo el eje central de las guías clínicas actuales.

Sin embargo, la tecnología DXA genera un espectro de información considerablemente más rico

que un único T-score. Los equipos modernos —como el GE Lunar Prodigy utilizado en el CIMOHU— producen, en un mismo examen y sin irradiación adicional, cientos de variables que comprenden la composición corporal regional (masa grasa, masa magra y masa ósea por región anatómica), el Análisis Estructural de Cadera (*Hip Structural Analysis*, HSA) con métricas de geometría cortical y rigidez seccional, y la Evaluación de Fractura Vertebral (VFA) con morfometría de cuerpos vertebrales. La práctica clínica habitual descarta la práctica totalidad de esta información para emitir un diagnóstico basado en uno o dos T-scores.

Esta reducción a un único escalar colapsa una señal multidimensional rica, omitiendo características geométricas, estructurales y de composición corporal que tienen valor predictivo independiente para el riesgo de fractura [11]. Es precisamente esta brecha —un instrumento de referencia que genera datos multimodales subutilizados— la que ha motivado la aplicación del aprendizaje automático a la predicción de la osteoporosis, como se detalla a continuación.

Modelos de aprendizaje automático para osteoporosis

El estudio de Yoo et al. [12] constituyó uno de los primeros referentes del uso de ML para predicción de osteoporosis, aplicando SVM, *Random Forest* y redes neuronales artificiales en mujeres coreanas posmenopáusicas y alcanzando un AUC de 0,827. Desde entonces, la literatura ha evolucionado rápidamente. Je et al. [13] aplicaron XGBoost sobre la cohorte KoGES Ansan-Ansung de Corea del Sur (4.199 mujeres), obteniendo un AUC de 0,84 y superando a ORAI (0,74) y OST (0,71). Jin et al. [14] entrenaron XGBoost con valores SHAP sobre registros de historia clínica electrónica en China y validaron el modelo de forma transcultural en datos de EE. UU., alcanzando AUC de 0,805–0,811. Carvalho y Gavaia [15] lograron el mayor desempeño reportado hasta la fecha —AUC 0,94 con exactitud del 93 %— mediante un ensamble de apilamiento que combina *Gradient Boosting*, *Random Forest*, XGBoost y LightGBM, sin utilizar datos DXA; su variable objetivo combina el criterio densitométrico de la OMS con criterios antropométricos de percentil extremo (peso, edad y circunferencia muscular del brazo) sobre datos clínicos y bioquímicos de NHANES, lo que constituye una tarea de clasificación distinta y lo excluye como cota de comparación directa para modelos entrenados y evaluados exclusivamente sobre T-score DXA. Un metaanálisis de pruebas diagnósticas de Rahim et al. [16] centrado específicamente en imágenes DXA de cadera (7 estudios; ~314.000 pacientes) reportó una sensibilidad agrupada de 0,844, especificidad de 0,781 y AUC sROC de 0,878. A escala aún mayor, Wu et al. [17] revisaron 53 estudios con más de 15 millones de pacientes y estimaron un C-index agrupado de 0,75

para la predicción de riesgo de fractura mediante ML.

En el contexto latinoamericano, la literatura sobre aprendizaje automático aplicado a la fragilidad ósea es sumamente escasa, evidenciando una brecha tecnológica significativa. Un esfuerzo pionero en la región es el de Miranda et al. [18], quienes en Chile utilizaron Máquinas de Vectores de Soporte (SVM) con eliminación recursiva de características (RFE) sobre datos de ultrasonido de transmisión axial bidireccional (BDAT) y variables clínicas (edad, IMC y uso de glucocorticoides). El modelo alcanzó una exactitud de clasificación del 71 %, cifra que los propios autores comparan directamente con el AUC de 0,71 reportado para la DXA femoral como referencia en el mismo estudio; dado que exactitud y AUC-ROC son métricas conceptualmente distintas (la primera depende del umbral de decisión y del balance de clases, la segunda no), esta equivalencia numérica debe interpretarse como una aproximación informal de los propios autores y no como una equivalencia estadística estricta. Con ese matiz, el estudio establece un *baseline* regional de rendimiento algorítmico, evidenciando el amplio margen de mejora que la integración de datos DXA multimodales de mayor fidelidad puede aportar en poblaciones hispanas. Un segundo referente clave proviene de Argentina: Vega et al. [19] entrenaron una red neuronal artificial (ANN-MLP) sobre datos densitométricos y antropométricos DXA de 478 mujeres, alcanzando un AUC de $0,81 \pm 0,03$ —el mejor resultado documentado con datos DXA reales en América Latina— y demostrando que la información multimodal del equipo estándar contiene señal predictiva relevante para la estratificación del riesgo en contextos LMIC. Destaca también el trabajo de Albuquerque, Carvalho, Cruz et al. [20], quienes aplicaron *Random Forest* sobre la población brasileña utilizando señales de atenuación de ondas electromagnéticas del dispositivo portátil “Osseus” —un equipo de investigación especializado, no disponible en entornos clínicos estándar— y reportaron un AUC de 0,894. Si bien este resultado confirma que existe señal predictiva en poblaciones latinoamericanas, el dispositivo “Osseus” no es equiparable al DXA clínico: no genera composición corporal regional, geometría ósea (HSA) ni morfometría vertebral (VFA). Por tanto, la brecha de modelos predictivos basados en las modalidades multimodales del DXA estándar para la región sigue intacta.

Fragmentación de modalidades y brecha multimodal

A pesar de estos avances, la literatura existente presenta una fragmentación metodológica importante. Los estudios de ML para osteoporosis han abordado las modalidades de datos de manera aislada: algunos utilizan exclusivamente datos tabulares de cuestionarios o historia clínica [12, 13], otros se enfocan únicamente en la segmentación de imágenes DXA o radiografías [21], y algunos emplean

radiografías dentales o imágenes de muñeca como aproximaciones indirectas a la DMO. Revisiones recientes sobre IA en osteoporosis subrayan que la integración multimodal —combinando señales de imagen, geometría ósea, composición corporal y factores clínicos— es la frontera activa del campo, a la vez que señalan la heterogeneidad metodológica y la falta de validación externa como limitaciones persistentes [22, 23]. Algunos trabajos han dado pasos en esa dirección: Wu et al. [24] fusionaron radiografías de tórax con datos clínicos en un modelo de *deep learning* y mejoraron el AUC de 0,951 a 0,975, aunque su estudio se limita a dos modalidades y carece de validación externa. Hasta la fecha, ningún estudio ha integrado de forma sistemática el espectro completo de modalidades que el DXA clínico genera —DMO, composición corporal, HSA y morfometría vertebral— en un *pipeline* unificado entrenado sobre una cohorte latinoamericana.

El análisis estructural de cadera (HSA) provee métricas geométricas —longitud del eje de la cadera (HAL), índice de sección de módulo compuesto (CSMI), área de sección transversal (CSA) y ancho cortical— que capturan la resiliencia estructural del hueso de manera tridimensional a partir de un escaneo DXA bidimensional. La combinación de estas variables con la DMO y la composición corporal (masa magra y grasa por región) genera un perfil multimodal latente que los modelos actuales no han explotado de forma integral.

Brecha geográfica: Costa Rica y Centroamérica

La inmensa mayoría de los modelos de ML publicados han sido entrenados y validados con datos de Asia Oriental, Europa o América del Norte. Los estudios publicados con datos costarricenses —Castro-Gamboa et al. [6], Moncada-Jiménez et al. [8], Montiel-Ojeda, Cerdas-Pérez, Clark et al. [25] y Cerdas-Pérez et al. [3]— se limitan a análisis estadísticos descriptivos y epidemiológicos y no aplican técnicas de ML. No existe ningún modelo de predicción de osteoporosis basado en ML que haya sido calibrado específicamente con datos de la población costarricense o centroamericana. Esta brecha es la que la presente investigación busca cerrar, aprovechando el activo de datos DXA del CIMOHU.

Síntesis de la revisión

En conjunto, la revisión de la literatura evidencia una evolución sostenida desde herramientas clínicas de cribado de baja resolución hacia modelos de ML progresivamente más precisos, pero revela tres brechas fundamentales que ningún estudio ha abordado de forma conjunta: (i) la fragmentación de las modalidades DXA en enfoques unimodales, que desaprovecha el espectro completo de información

que el equipo genera; (ii) la carencia total de modelos calibrados para la población costarricense o centroamericana, pese a que Medina et al. [4] y Cerdas-Pérez et al. [3] documentan patrones epidemiológicos propios de la región; y (iii) la subutilización del activo de datos DXA del CIMOHU. Estas brechas son precisamente las que estructuran el problema de investigación presentado en la sección siguiente.

1.4. Descripción del problema

Pregunta de investigación

La brecha identificada en la literatura conduce a la siguiente pregunta de investigación que guía este trabajo:

¿Puede un modelo de ML multimodal —entrenado con datos de DMO, composición corporal, análisis estructural de cadera y morfometría vertebral del CIMOHU— superar en al menos $\Delta AUC \geq 0,05$ a los comparadores clínicos de línea base ejecutables sobre los datos disponibles —T-score umbral, OST y regresión logística mínima (edad + sexo + IMC)— en la clasificación binaria osteoporosis vs. no osteoporosis en adultos costarricenses?

Brechas específicas

Ningún estudio publicado ha construido un modelo de ML para la estratificación del riesgo de osteoporosis utilizando datos DXA multimodales reales de una población latinoamericana o costarricense. La contribución de esta investigación no es proponer un nuevo dispositivo diagnóstico, sino demostrar el valor latente de los datos que el equipo DXA estándar ya genera en contextos clínicos reales —datos que la práctica clínica habitual descarta— y construir el primer *pipeline* multimodal calibrado con una cohorte costarricense. Las brechas específicas que esta investigación aborda son:

- Las herramientas de cribado clínico disponibles (FRAX®, OST, ORAI) están calibradas para poblaciones caucásicas y pueden clasificar erróneamente a pacientes costarricenses, sin que exista un comparador validado localmente.
- Los modelos de ML publicados emplean modalidades únicas (sólo DMO tabular o sólo imágenes), sin integrar el espectro multimodal que el equipo DXA genera (DMO + composición corporal + HSA + morfometría vertebral) en un *pipeline* unificado.

- La base de datos DXA del CIMOHU —17 años de datos de 3.240 pacientes costarricenses— no ha sido analizada con técnicas de ML, constituyendo un activo científico sin explotar.

1.5. Hipótesis

H: Un modelo de ML multimodal entrenado sobre los datos DXA del CIMOHU superará en $\Delta AUC \geq 0,05$ a los comparadores clínicos de línea base ejecutables sobre los datos disponibles —T-score umbral, OST y regresión logística mínima (edad + sexo + IMC)— en la clasificación binaria osteoporosis vs. no osteoporosis sobre la cohorte CIMOHU.

Equivalentemente en notación formal:

$$\Delta AUC \triangleq AUC(\hat{M}) - \max_{f \in \mathcal{B}} AUC(f) \geq 0,05 \quad (1.1)$$

donde $\hat{M}$ denota el mejor modelo ML multimodal entrenado sobre los datos DXA del CIMOHU y $\mathcal{B} = \{f_{\text{T-score}}, f_{\text{OST}}, f_{\text{LR}(\text{edad}+\text{sexo}+\text{IMC})}\}$ es el conjunto de comparadores clínicos de línea base.

Condiciones de evaluación. El objetivo de H es cuantificar la superioridad del enfoque multimodal DXA sobre el estándar diagnóstico actual, excluyendo modelos construidos con tecnologías de adquisición distintas al DXA (§ 1.3). La diferencia en AUC será estadísticamente significativa con la prueba pareada de DeLong [26] ($p < 0,05$). El modelo conservará interpretabilidad mediante valores SHAP.

De forma complementaria y pre-especificada, H también se evaluará mediante:

$$\Delta F1 \triangleq F1(\hat{M}) - F1(f_{\text{ref}}) \geq 0,10 \quad (1.2)$$

H se considerará respaldada si se satisface al menos uno de los dos criterios pre-especificados:

$$\text{H respaldada} \iff \underbrace{(\Delta AUC \geq 0,05 \wedge p_{\text{DeLong}} < 0,05)}_{\text{criterio primario}} \vee \underbrace{(\Delta F1 \geq 0,10 \wedge AUC(\hat{M}) \geq AUC(f_{\text{ref}}))}_{\text{criterio complementario}} \quad (1.3)$$

Los umbrales numéricos, la regla de decisión y los riesgos metodológicos asociados se pre-especifican en § 3.5; los valores del comparador de línea base que anclan dichos umbrales se reportan en § 4.4 (Tabla 4.4).

1.6. Objetivos

Objetivo general

Desarrollar, comparar y evaluar múltiples modelos de aprendizaje automático para la predicción del riesgo de osteoporosis en adultos costarricenses, utilizando datos DXA multimodales del CIMOHU, con el fin de identificar el algoritmo que ofrece la mayor precisión y exactitud para este escenario clínico y poblacional.

Objetivos específicos

1. **OE1:** Construir un *dataset* integrado y multimodal a partir de la base de datos DXA del CIMOHU, unificando registros de densitometría (128.910), composición corporal (94.709), T-scores/Z-scores (475.205), análisis estructural de cadera (HSA, 1.530) y morfometría vertebral (2.499), con limpieza, normalización y manejo de datos faltantes.
2. **OE2:** Desarrollar un modelo de clasificación transversal del riesgo de osteoporosis, entrenando y comparando múltiples algoritmos de ML —SVM, *Random Forest*, XGBoost/LightGBM y redes neuronales artificiales— sobre el *dataset* multimodal del CIMOHU. La variable objetivo primaria, y la única formalmente evaluada por H mediante AUC-ROC y la prueba de DeLong, es la clasificación **binaria** osteoporosis vs. no osteoporosis ($T\text{-score} \leq -2,5$ vs. $> -2,5$); la clasificación de tres niveles de la OMS (Normal / Osteopenia / Osteoporosis) se reportará de forma descriptiva y exploratoria como caracterización adicional del riesgo, sin sustituir la formulación binaria de H.
3. **OE3:** Comparar el rendimiento de todos los algoritmos bajo condiciones idénticas de datos y partición, evaluar la contribución marginal de cada modalidad DXA mediante análisis de ablación, e interpretar los modelos mediante valores SHAP y *permutation importance*, generando un *ranking* fundamentado con recomendación del modelo más adecuado para la población costarricense.

1.7. Alcance y limitaciones

El presente estudio se enmarca en un análisis retrospectivo de datos secundarios, obtenidos de la base de datos `prodigy.db` del CIMOHU. El alcance se limita a la población de adultos costarricenses

registrados en ese sistema entre 2009 y 2026 y no incluye datos de otras instituciones ni la realización de exámenes clínicos nuevos.

Los modelos desarrollados no constituyen una herramienta de diagnóstico clínico certificada; su aplicación clínica requeriría validación externa prospectiva y aprobación regulatoria por las autoridades competentes. Asimismo, el estudio no contempla el procesamiento de imágenes DXA crudas (archivos DICOM) ni el uso de redes neuronales convolucionales sobre esas imágenes, lo que queda señalado como línea de trabajo futuro.

Capítulo 2

Marco teórico

El presente capítulo expone los fundamentos teóricos y matemáticos que sustentan esta investigación. Se abordan, en primer lugar, los conceptos clínicos de la densitometría ósea, el diagnóstico de la osteoporosis y las modalidades multimodales que el equipo DXA genera más allá del T-score. A continuación se detallan las arquitecturas algorítmicas de aprendizaje automático empleadas en el análisis de clasificación transversal, las métricas de evaluación relevantes y los métodos de interpretabilidad necesarios para la validación de modelos en el ámbito clínico.

2.1. Densitometría ósea, diagnóstico de la osteoporosis y modalidades DXA

La osteoporosis es una enfermedad esquelética sistémica de carácter metabólico, caracterizada por la disminución de la masa ósea y el deterioro de la microarquitectura del tejido óseo, lo cual conduce a un incremento sustancial en la fragilidad ósea y el riesgo de fracturas. Clínicamente, el estándar de oro para su diagnóstico es la Absorciometría de Rayos X de Energía Dual (DXA), una técnica radiológica bidimensional que cuantifica la Densidad Mineral Ósea (DMO).

De acuerdo con los criterios de la Organización Mundial de la Salud (OMS), el diagnóstico se establece mediante el *T-score*, una métrica que representa el número de desviaciones estándar en las que la DMO del paciente se aleja de la media de una población adulta joven y sana [10]. Un *T-score* $\leq -2,5$ indica osteoporosis; valores entre $-2,5$ y $-1,0$ denotan osteopenia; y valores $\geq -1,0$ se consideran normales.

A pesar de su adopción universal, el *T-score* basado exclusivamente en la DMO presenta limitaciones fundamentales al colapsar un sistema tridimensional complejo, capturado mediante una proyección bidimensional, en un único escalar. La resistencia mecánica del hueso depende no solo de la densidad, sino de la geometría, la microarquitectura trabecular y la integridad cortical [11]. Para solventar esta brecha, los equipos DXA modernos —como el GE Lunar Prodigy utilizado en el CIMOHU— proveen un conjunto de modalidades complementarias latentes que esta investigación integra como *features*

predictivos.

Análisis Estructural de Cadera (HSA)

El *Hip Structural Analysis* (HSA), desarrollado originalmente por Beck et al. [27], deriva métricas de geometría ósea tridimensional directamente del escaneo DXA bidimensional mediante análisis de la distribución de masa mineral a lo largo del cuello femoral. Las variables clave incluyen la Longitud del Eje de la Cadera (HAL), el Área de Sección Transversal (CSA), el Índice de Sección de Módulo Compuesto (CSMI) y el Ancho Cortical. Estas métricas capturan la resiliencia estructural del hueso de forma independiente a la densidad puntual, y representan 1.530 registros disponibles en la base de datos del CIMOHU. Estudios longitudinales con DXA han demostrado que, tras una fractura de cadera, los pacientes experimentan declives acelerados en el Módulo de Sección (SM) y el Área de Sección Transversal (CSA), acompañados de aumentos compensatorios en el Diámetro Externo (OD) en las regiones del cuello estrecho e intertrocanterea [28]. Estas trayectorias de degradación geométrica presentan variaciones significativas según el sexo [29] y se asocian a declives en la DMO entre 2,65 y 5 veces superiores (según el sitio anatómico) a los observados en sujetos no fracturados de edad equivalente [30]. Estos hallazgos justifican la inclusión de los parámetros HSA como *features* predictivos independientes de la DMO en el *pipeline* del presente proyecto.

Evaluación de Fractura Vertebral (VFA)

La *Vertebral Fracture Assessment* (VFA) permite la detección semicuantitativa de deformidades vertebrales mediante la medición de alturas anteriores, medias y posteriores de los cuerpos vertebrales (T6–L4) a partir de una imagen de baja dosis de radiación obtenida en el mismo examen DXA. La clasificación semicuantitativa de Genant et al. [31] define tres grados de deformidad —leve, moderada y severa— según la reducción proporcional de altura vertebral respecto a la vértebra de referencia. El *dataset* del CIMOHU contiene 2.499 registros de morfometría vertebral, que constituyen una capa multimodal clave para el análisis de ablación previsto en el objetivo específico 3.

Composición corporal regional

El equipo DXA segmenta el cuerpo en regiones anatómicas —cabeza, tronco, pelvis, extremidades superiores e inferiores, zonas android y gynoid— cuantificando independientemente la masa grasa, la masa magra y la masa ósea por región. Los 94.709 registros de composición corporal del CIMOHU son

la segunda fuente de *features* más rica del *dataset*, y su desglose regional permite modelar asimetrías y distribuciones de grasa visceral que el Índice de Masa Corporal (IMC) global no captura.

La integración de la masa muscular magra es de particular relevancia debido al fenómeno fisiológico de *cross-talk* entre músculo y hueso, conocido clínicamente como **osteosarcopenia**: la coexistencia de baja masa ósea (osteopenia u osteoporosis) y sarcopenia en el mismo individuo, un síndrome revisado y sistematizado por Kirk, Zanker y Duque [32] que amplifica sinérgicamente el riesgo de caídas y fracturas respecto al de cada condición por separado.

La base biológica de esta interacción es bidireccional [32]: las miocinas secretadas por el músculo esquelético —miostatina, folistatina e irisina— modulan directamente la remodelación ósea (la miostatina induce osteoclastogénesis; la folistatina y la irisina inhiben la resorción ósea), mientras que las osteocinas producidas por el hueso —osteocalcina y conexina 43— regulan el anabolismo y catabolismo muscular en sentido inverso. Adicionalmente, la acumulación de grasa intramuscular e intramedular propia del envejecimiento secreta adipocinas que inducen apoptosis coordinada de miocitos y osteocitos. Esta interacción tripartita músculo-hueso-grasa fundamenta la necesidad de capturar simultáneamente variables de las tres categorías en cualquier modelo predictivo de riesgo musculoesquelético.

Las consecuencias clínicas de la osteosarcopenia son cuantificables y superan las de sus componentes aislados: en adultos mayores con ambas condiciones, el riesgo de caídas (OR: 2,83–3,63; $p < 0,05$) y de fracturas (OR: 3,86–4,38; $p < 0,05$) es significativamente mayor que en individuos sin osteosarcopenia [32]. Críticamente, a la fecha no existen herramientas de cribado ni modelos predictivos validados específicamente para la detección de osteosarcopenia [32], lo que representa una brecha directamente abordable por el enfoque multimodal propuesto en esta tesis.

El DXA posee la ventaja operativa de cuantificar simultáneamente la DMO y la masa magra apendicular (ALM), de modo que ambas fuentes de información provienen del mismo equipo y protocolo de adquisición. Kirk, Zanker y Duque [32] demostraron que la sarcopenia es un predictor independiente de caída y fractura, y que el deterioro muscular precede y agrava el óseo. Esta asociación ha sido documentada en poblaciones de alto riesgo clínico: en adultos mayores con infección por VIH estable, la masa muscular apendicular (ASMI) se correlacionó significativamente con la DMO femoral y lumbar [33]. En el contexto local, Barrientos-Calvo y Picado-Ovares [34] determinaron que la sarcopenia afecta a una proporción significativa de adultos mayores costarricenses, validando la necesidad de incorporar índices de composición corporal extraídos del DXA en los vectores predictivos. Esta interconexión justifica incluir simultáneamente DMO, composición corporal, geometría estructural y morfometría como

features predictivos, en línea con estudios que evidencian que la fusión imagen+clínica mejora sobre modelos unimodales, aunque dichos estudios operan con muestras limitadas y carecen de validación externa [22, 24, 23]. La Figura 2.1 ilustra conceptualmente cómo las cuatro modalidades del densitómetro se integran, en principio, en un único vector de características que alimenta la escalera de modelos de ML.

Sin embargo, en la base de datos del CIMOHU la cohorte de pacientes con T-score válido de columna y/o cadera y la cohorte con escaneo de cuerpo completo (necesario para extraer composición corporal) son **casi mutuamente excluyentes** ($n = 2.591$ y $n = 665$ respectivamente, con solo 42 pacientes en común). Esta disyunción se explica porque el CIMOHU es utilizado con frecuencia para análisis metabólicos generales —evaluación nutricional y deportiva de composición corporal en población relativamente joven— y no exclusivamente como centro de referencia para el diagnóstico de osteoporosis, lo cual explica también la juventud relativa de la submuestra de cuerpo completo frente a la cohorte clásica de osteoporosis [34]. Por esta razón, la contribución de la composición corporal al riesgo de osteoporosis se evalúa mediante un modelo de ablación entrenado sobre la intersección real de ambas cohortes ($n = 42$ pacientes), de forma separada al modelo principal de clasificación transversal (Fase 2, § 3.3), en lugar de fusionarla directamente en un único vector de *features* para toda la cohorte.

Indicio empírico propio, de carácter exploratorio: el tejido blando podría estar asociado a la densidad ósea incluso en poblaciones jóvenes. La evaluación preliminar de este modelo de ablación sobre los datos del CIMOHU (Piloto B', § 4.5) es consistente con la premisa teórica de esta sección, aunque con el carácter no concluyente propio de una muestra de $n = 42$. Mediante regresión con Validación Cruzada *Leave-One-Out* sobre el T-score continuo de los 42 pacientes de la intersección —una sub-cohorte sistemáticamente más joven y sana que la población clínica de referencia para osteoporosis, condición *a priori* menos favorable para detectar una asociación entre tejido blando y hueso—, las variables puramente demográficas (edad, sexo, IMC) explican apenas el 12,4 % de la varianza observada del T-score ($R^2 = 0,124$). Al incorporar las variables de composición corporal (masa grasa, masa magra y porcentaje de grasa), el poder explicativo observado casi **se triplica** hasta un 38,1 % ($R^2 = 0,381$), sin que esta diferencia se haya sometido a una prueba formal de significancia y con el matiz de que el porcentaje de grasa es una función determinística de las otras dos variables de composición incluidas en el mismo modelo, lo que introduce colinealidad (§ 3.3). Este patrón preliminar es **compatible con** —sin constituir, por sí solo, prueba concluyente de— la evidencia de la literatura internacional [35, 33] de que los tejidos blandos —músculo y grasa— se asocian a la densidad

ósea incluso en poblaciones jóvenes y relativamente sanas, lo que refuerza, junto con esa literatura, la justificación científica para aislar y extraer estas variables del examen DXA como *features* predictivos independientes en la Fase 3, en lugar de descartarlas por la limitada superposición muestral con la cohorte etiquetada principal.




Figura 2.1: Diagrama conceptual de la integración multimodal propuesta. Las cuatro modalidades DXA generadas por el equipo GE Lunar Prodigy del CIMOHU se fusionan, en principio, en un vector de características unificado que alimenta la escalera de modelos de ML. En la práctica, dada la casi disyunción entre la cohorte con T-score y la cohorte con escaneo de cuerpo completo (§ 2.1), la composición corporal se evalúa mediante un modelo de ablación independiente sobre su propia submuestra (Fase 2, § 3.3), mientras que el modelo principal integra DMO, demografía y HSA.

2.2. Aprendizaje automático para clasificación transversal

Para superar las limitaciones del enfoque umbral del diagnóstico clínico tradicional, se plantea el uso de algoritmos de Aprendizaje Automático (ML) para clasificación supervisada. Esta investigación emplea una escalera de complejidad que permite comparar el rendimiento incremental de distintos enfoques bajo condiciones idénticas de datos y partición.

Regresión logística

La regresión logística es un modelo lineal interpretable que sirve como *baseline* mínimo junto al T-score umbral y al índice OST. Establece el piso de rendimiento contra el cual se mide la ganancia de los modelos más complejos y permite verificar que la señal del *dataset* multimodal supera a la predicción univariada. Este modelo se implementa como *baseline* clínico en la Fase 3 de la metodología (§ 3.4).

Random Forest

Random Forest es un método de ensamble basado en la construcción de múltiples árboles de decisión durante el entrenamiento. Utiliza técnicas de *bagging* (muestreo con reemplazo) y selección aleatoria de subconjuntos de características (*random subspace*) en cada nodo, lo que lo hace altamente robusto frente al ruido y a problemas de multicolinealidad. Provee una estimación nativa de importancia de *features* por reducción de impureza de Gini, útil para el análisis de ablación multimodal previsto en el objetivo específico 3. Este algoritmo se entrena en la Fase 3 (§ 3.4); su importancia por impureza complementa el análisis SHAP de la Fase 4 (§ 3.5).

XGBoost y LightGBM

XGBoost (*eXtreme Gradient Boosting*) y LightGBM son algoritmos de ensamble basados en árboles de decisión que emplean la técnica de *gradient boosting*. A diferencia de *Random Forest*, construyen árboles de forma secuencial, donde cada nuevo árbol se optimiza matemáticamente para corregir los residuos de los anteriores. Incorporan regularización intrínseca (L1 y L2) para prevenir el sobreajuste y manejan datos faltantes de forma nativa —una ventaja crítica dada la naturaleza heterogénea del *dataset* del CIMOHU.

Estos algoritmos son los de mayor rendimiento en la literatura reciente de predicción de osteoporosis: Je et al. [13] reportan un AUC de 0,84 con XGBoost, superando a ORAI (0,74) y OST (0,71); Jin et al. [14] alcanzan AUC de 0,805–0,811 en validación transcultural; Carvalho y Gavaia [15] logran el techo actual del estado del arte con AUC 0,94 y exactitud del 93 % mediante un ensamble de apilamiento que incluye XGBoost y LightGBM como estimadores base —aunque, como se discute en § 1.5, sobre datos tabulares sin DXA y con una variable objetivo no directamente comparable a la de este trabajo. Ambos algoritmos se evalúan en la Fase 3 de la metodología (§ 3.4), donde forman la columna vertebral del ensamble de clasificación multimodal.

Support Vector Machines

Las *Support Vector Machines* (SVM) proyectan los datos a un espacio de mayor dimensión a través de una función *kernel* —como la Función de Base Radial (RBF)— para encontrar el hiperplano óptimo que maximiza el margen de separación entre clases. Este método es altamente efectivo para capturar no linealidades complejas en datos biométricos y fue el mejor predictor en el estudio seminal de Yoo

et al. [12], con AUC de 0,827. Las SVM se incluyen en la escalera de complejidad de la Fase 3 (§ 3.4) para evaluar su rendimiento frente a los métodos basados en árboles con el *dataset* CIMOHU.

Red neuronal perceptrón multicapa (MLP)

La arquitectura de perceptrón multicapa (MLP) es una red neuronal totalmente conectada que aprende representaciones no lineales jerárquicas de los *features* de entrada mediante capas ocultas y funciones de activación no lineales. Actúa como referencia de comparación para los enfoques de *deep learning* tabular en la Fase 3 (§ 3.4).

Manejo del desbalance de clases

La base de datos del CIMOHU presenta un desbalance intrínseco, con aproximadamente un 15,5 % de las visitas de la cohorte etiquetada en la clase de osteoporosis ($T\text{-score} \leq -2,5$; véase § 3.3). Para abordarlo, se combinan tres técnicas complementarias. En primer lugar, SMOTE (*Synthetic Minority Over-sampling Technique*), propuesto por Chawla et al. [36], sobremuestra la clase minoritaria interpolando matemáticamente entre instancias existentes y sus vecinos más cercanos en el espacio de características, generando ejemplos sintéticos que generalizan la región de decisión sin incurrir en la copia directa de datos. En segundo lugar, se asignan pesos de clase inversamente proporcionales a la frecuencia de cada clase durante el entrenamiento. En tercer lugar, se optimizan los umbrales de decisión mediante la curva de precisión-recuperación. Esta combinación evita tanto el sobreajuste sobre la clase mayoritaria como la generación de ejemplos sintéticos fuera de la distribución real. Este procedimiento de balanceo se aplica exclusivamente sobre la partición de entrenamiento interna de cada pliegue de la validación cruzada —nunca sobre el conjunto de entrenamiento completo antes de dicha partición— para prevenir la fuga de información sintética entre pliegues, tal como se detalla en la Fase 2 (§ 3.3) y en el blindaje metodológico de la Fase 4 (§ 3.5).

2.3. Métricas de evaluación

Las métricas de evaluación están directamente vinculadas a la hipótesis H de este trabajo.

Métricas de clasificación transversal

El Área Bajo la Curva ROC (AUC-ROC) es la métrica principal para H. Representa la probabilidad de que el modelo asigne un riesgo mayor al paciente con osteoporosis que al sano en un par comparado aleatoriamente, y es robusta ante el desbalance de clases. Permite la prueba pareada de DeLong para comparación estadística entre modelos ($p < 0,05$). Como métricas complementarias se utilizan precisión, sensibilidad, especificidad, F1-score y el Coeficiente de Correlación de Matthews (MCC), este último especialmente informativo bajo desbalance severo de clases.

2.4. Interpretabilidad de modelos y valores SHAP

La adopción de arquitecturas de ML complejas en entornos médicos exige sistemas transparentes; los modelos de “caja negra” carecen de aplicabilidad clínica al no proporcionar un razonamiento auditable que permita a un clínico comprender, cuestionar o validar la predicción.

Para garantizar la interpretabilidad global y local, se implementa el marco algorítmico SHAP (*SHapley Additive exPlanations*), propuesto por Lundberg y Lee [37]. Basado en los Valores de Shapley de la teoría de juegos cooperativos, SHAP asigna un valor de importancia a cada característica evaluando su contribución marginal a la predicción final a través de todas las posibles coaliciones de variables. Este método garantiza matemáticamente tres propiedades axiomáticas deseables:

1. **Precisión local:** la suma de las contribuciones individuales de todas las características iguala exactamente la predicción del modelo para cada instancia.
2. **Falta** (*missingness*): las características ausentes reciben contribución cero, evitando que variables con datos faltantes inflen artificialmente su importancia.
3. **Consistencia:** si el modelo cambia de forma que una variable contribuye más a la predicción bajo cualquier coalición posible, su valor SHAP no disminuye.

Al aplicar SHAP es posible desglosar el perfil de predicción de cada paciente, identificando exactamente cuánto influye la DMO en un sitio anatómico frente a variables de morfometría vertebral, índices de masa magra o métricas geométricas de HSA en el cálculo de su riesgo. En el contexto multimodal de esta investigación, los valores SHAP permiten cuantificar la contribución marginal de cada modalidad DXA —equivalente a un análisis de ablación explicable— lo que constituye evidencia científica sobre el valor incremental de integrar HSA y morfometría más allá de la DMO pura.

Complementariamente, se implementa la importancia de características por permutación (*permutation importance*), que evalúa la degradación del rendimiento del modelo al permutar aleatoriamente los valores de cada variable en el conjunto de validación. A diferencia de la importancia por impureza de Gini —sesgada hacia variables de alta cardinalidad—, la importancia por permutación es agnóstica al algoritmo y mide el impacto real sobre la métrica de evaluación primaria (AUC-ROC).

Capítulo 3

Metodología

Este capítulo describe el marco metodológico diseñado para abordar el problema de investigación y comprobar las hipótesis planteadas. Se detalla el diseño del estudio, el flujo de procesamiento de datos (*pipeline*), el entrenamiento de la escalera de algoritmos de aprendizaje automático y el esquema de validación estadística e interpretabilidad. Finalmente, se presenta el cronograma de trabajo estipulado para la ejecución del proyecto.

3.1. Diseño de la investigación

El presente estudio se clasifica como una investigación analítica retrospectiva basada en datos secundarios. Utiliza como fuente primaria la base de datos longitudinal del Centro de Investigación en Movimiento Humano (CIMO HU) de la Universidad de Costa Rica [38]. El *pipeline* metodológico se divide en cuatro fases secuenciales que abarcan desde la consolidación del *dataset* hasta la validación clínica de los modelos predictivos, como se ilustra en la Figura 3.1.




Figura 3.1: *Pipeline* metodológico de cuatro fases. Cada fase corresponde a uno o más objetivos específicos (OE) de la investigación. Las fases se ejecutan secuencialmente; los resultados de cada fase son la entrada de la siguiente.

3.2. Fase 1: Consolidación y preprocesamiento (*ETL*)

La primera fase consiste en la extracción, transformación y carga (ETL) de los datos crudos. El equipo DXA (GE Lunar Prodigy) del CIMOHU ha generado 27 respaldos históricos en formato *.mdb* a lo largo de 17 años (2009–2026).

- **Consolidación:** Se migrarán y unificarán los 27 respaldos hacia una base de datos relacional robusta (SQLite, `prodigy.db`), integrando un total de 9.426 exámenes correspondientes a los 3.240 pacientes adultos registrados (3.231 con al menos un examen).
- **Control de calidad y limpieza:** Se aplicará la de-duplicación por identificador de paciente (`patient_id`) y fecha. Se validarán los rangos clínicos permisibles (e.g., valores de DMO positivos, T-scores entre -6 y $+6$) para aislar posibles artefactos o *drift* instrumental. La fidelidad instrumental del equipo GE Lunar Prodigy del CIMOHU ha sido validada localmente por Chacón-Araya, Carpio-Rivera y Moncada-Jiménez [39], quienes reportaron coeficientes de variación test-retest sumamente bajos (0,17 %-3,76 %), estableciendo un piso de reproducibilidad robusto para la extracción de características.
- **Imputación de datos:** Dada la naturaleza de los estudios retrospectivos, variables multimodales específicas como el Análisis Estructural de Cadera (HSA) y la Morfometría Vertebral (VFA) presentan valores faltantes. Se utilizarán técnicas de imputación múltiple por ecuaciones encadenadas (MICE) y análisis de sensibilidad para el manejo de estos vacíos.
- **Descarte de la variable “Etnia”:** Se elimina explícitamente la columna `ethnicity` del conjunto de datos. El 98,5 % de los pacientes figuran como “White”, un valor por defecto del software GE Lunar Prodigy que no representa la demografía costarricense real; conservarla introduciría ruido y sesgo en cualquier modelo predictivo.
- **Corrección del identificador de composición corporal de cuerpo completo:** La extracción de las variables de composición corporal (masa grasa, masa magra, masa ósea) se realizará filtrando estrictamente por `site=13` y `label=61` en la tabla `lunar__Composition`. El identificador `label=100`, utilizado erróneamente en una versión previa del *pipeline*, mezcla regiones parciales de cadera y columna, generando magnitudes sin sentido físico (decenas a cientos de gramos en lugar de las decenas de miles esperadas para un escaneo de cuerpo completo).
- **Exclusión de variables con fuga de información (*data leakage*):** Tanto los T-scores como la densidad ósea cruda (`bmd_total`) quedan excluidos, de forma explícita y permanente, del conjunto de variables predictoras de entrada (X) en todas las fases posteriores, dado que la etiqueta objetivo (Y , clasificación OMS de osteoporosis) se deriva matemáticamente de ellos.

3.3. Fase 2: Integración multimodal y manejo de desbalance

Reestructuración por exclusión mutua de cohortes. La base CIMOHU presenta una limitación estructural crítica: la cohorte de pacientes con T-score válido de columna y/o cadera (`site` $\in \{0, 1, 2, 3\}$; $n = 2.591$) y la cohorte con escaneo de cuerpo completo que permite extraer composición corporal (`site=13` y `label=61`, con masas estrictamente positivas; $n = 665$) son **casi mutuamente excluyentes**: únicamente 42 pacientes coinciden en ambas cohortes. (La auditoría general de la base de datos, sin el filtro de masas positivas aplicado en el *pipeline* de modelado, reporta 668 pacientes con al menos un registro de `site=13/label=61`; la diferencia de 3 pacientes corresponde a registros con masas nulas o negativas excluidos por control de calidad, véase § 3.2.) En consecuencia, no es viable fusionar todas las modalidades en un único *dataset* multimodal por paciente sin recurrir a una imputación masiva ($\sim 99\%$) de las variables de composición corporal dentro de la cohorte etiquetada, imputación que no aportaría señal real al modelo.

Ante esta restricción, el diseño se reestructura como un **análisis de ablación con dos modelos separados** en lugar de un modelo único totalmente fusionado:

- **Modelo principal (H):** entrenado sobre la cohorte etiquetada ($n = 2.591$) con las modalidades DMO, demografía y HSA. Es el modelo evaluado formalmente contra los comparadores clínicos en la Fase 4.
- **Modelo secundario (ablación de composición corporal):** entrenado sobre la intersección real de ambas modalidades a nivel de paciente ($n = 42$: pacientes con T-score válido y escaneo de cuerpo completo con composición corporal, filtrando estrictamente `site=13` y `label=61`, véase § 3.2), para medir de forma aislada el aporte del tejido blando (masa grasa y masa magra) sobre la densidad ósea.

Reformulación del modelo secundario como tarea de regresión. La auditoría numérica de la cohorte piloto (§ 4.5) reveló que los 42 pacientes de la intersección real presentan **cero casos de osteoporosis** (T-score peor observado = $-2,10$, por encima del umbral OMS de $-2,5$). Este hallazgo no es un artefacto muestral aleatorio, sino la manifestación de un **sesgo demográfico estructural del CIMOHU**: los pacientes que se someten a un escaneo de composición corporal de cuerpo completo acuden mayoritariamente por indicación deportiva o nutricional, y constituyen una subpoblación sistemáticamente más joven y sana que la cohorte clásica de referencia para osteoporosis. Con una sola clase presente, la tarea de **clasificación binaria es matemáticamente inviable** sobre esta

intersección (AUC-ROC, sensibilidad y especificidad quedan indefinidos). En consecuencia, el modelo secundario se reformula como una **tarea de regresión continua sobre el T-score** (`tscore_min`), que sí posee varianza suficiente en esta sub-cohorte (rango observado $\approx -2,10$ a $+4,36$), en lugar de una clasificación Normal/Osteoporosis.

Validación cruzada Leave-One-Out (LOOCV). Dado el tamaño de muestra reducido de esta sub-cohorte ($n = 42$), un único *holdout* 80/20 dejaría apenas ~ 8 pacientes en el conjunto de prueba, una base estadísticamente insuficiente para estimar el poder predictivo del modelo. Por ello, el modelo secundario se evalúa mediante **Validación Cruzada Leave-One-Out** (*Leave-One-Out Cross-Validation*, LOOCV), en la que cada uno de los 42 pacientes se predice a partir de un modelo entrenado con los 41 restantes. LOOCV constituye el estándar estadístico riguroso para muestras reducidas, ya que maximiza el uso de los datos disponibles para el entrenamiento en cada iteración y produce una estimación del error de generalización con varianza mínima entre pliegues. El desempeño se reporta mediante el coeficiente de determinación (R^2) y el Error Absoluto Medio (MAE) promediados sobre las 42 predicciones fuera de muestra.

Limitación cuantificada — multicolinealidad severa de las variables de composición corporal. El porcentaje de grasa corporal (`percent_fat_bodycomp`) se calcula como una función determinística de la masa grasa y la masa magra: $\%grasa = \text{grasa} / (\text{grasa} + \text{magra} + \text{ósea}) \times 100$. Incluir simultáneamente las tres variables en una regresión lineal con $n = 42$ introduce multicolinealidad severa, cuantificada en la Fase 6 del notebook mediante el Factor de Inflación de la Varianza (VIF, calculado con la fórmula estándar $VIF_j = 1/(1 - R_j^2)$, variables estandarizadas): `percent_fat_bodycomp` VIF = 83,3; `fat_mass` VIF = 41,3; `lean_mass` VIF = 25,6; variables demográficas VIF < 5. VIF > 10 indica multicolinealidad severa. Esta condición puede inflar el R^2 aparente sin implicar información independiente adicional. La confirmación en la Fase 3 deberá emplear regularización (Ridge/Lasso) o selección de variables que resuelva esta dependencia estructural antes de atribuir poder predictivo independiente a cada componente de la composición corporal.

Cada examen de la cohorte etiquetada será clasificado (Normal, Osteopenia u Osteoporosis) basándose estrictamente en el T-score del sitio anatómico más restrictivo, cumpliendo con los criterios de la OMS [10].

La prevalencia de osteoporosis (T-score $\leq -2,5$) en la cohorte etiquetada representa aproximadamente el 15,5 % de las visitas (581 de 3.742 visitas con T-score válido), consistente con el 15,9 % observado a nivel de paciente en la Tabla 4.2. Para mitigar el sesgo hacia la clase mayoritaria durante

el entrenamiento, se implementará la técnica de sobremuestreo sintético SMOTE (*Synthetic Minority Over-sampling Technique*) [36]. Este balanceo de clases se aplicará **exclusivamente sobre la partición de entrenamiento interna de cada pliegue** de la validación cruzada (nunca sobre el conjunto de entrenamiento completo antes de dicha partición), garantizando que ninguna observación sintética contamine los pliegues de validación ni el conjunto de prueba; el procedimiento completo se detalla en la Fase 4 (§ 3.5).

3.4. Fase 3: Desarrollo de modelos de clasificación transversal

Se establecerá un *benchmark* de algoritmos de aprendizaje automático para predecir el estado de riesgo en una evaluación transversal. Se construirá una “escalera de complejidad” que contempla:

- Modelos lineales e interpretables: Regresión Logística (utilizada como línea base clínica).
- Modelos basados en árboles y ensambles: *Random Forest*, XGBoost y LightGBM.
- Modelos de fronteras no lineales: Máquinas de Vectores de Soporte con *kernel* radial (SVM-RBF) y Perceptrón Multicapa (MLP).

Definición blindada del comparador de línea base para H. El comparador mínimo de la hipótesis H es una regresión logística entrenada exclusivamente con tres variables demográficas: **edad, sexo e IMC**. Esta definición es única y estricta: no existe una distinción entre un “piloto” descriptivo exploratorio y el comparador formal utilizado en la prueba estadística final de la Fase 4 — ambos son, por definición, el mismo experimento con las mismas tres variables, de modo que cualquier resultado piloto reportado es directamente el resultado del comparador de H. Estas tres variables reproducen la información disponible en una consulta médica estándar sin DXA, y son los predictores que utilizan las herramientas de cribado clínico convencionales (OST: edad + peso; ORAI: edad + peso + uso de estrógenos).

Se excluyen explícitamente de este comparador tanto los T-scores y el BMD bruto —por fuga de información, ya que la etiqueta de clasificación se deriva matemáticamente de ellos— como las variables de masa grasa y masa magra, aun cuando estuvieran disponibles para el paciente. Esta segunda exclusión no responde a un criterio de *leakage*, sino a una decisión de diseño: el comparador debe simular una consulta médica de bajo nivel de recursos, sin acceso a información de composición corporal del DXA, para constituir un piso de comparación clínicamente realista y no artificialmente favorecido

por variables propias del instrumento. La misma exclusión de T-scores y BMD bruto aplica a los modelos avanzados de la escalera: el modelo principal (DMO + demografía + HSA, cohorte etiquetada) y el modelo secundario de ablación de composición corporal (submuestra de cuerpo completo, § 3.3) compiten cada uno sobre su propio espacio de características DXA, sin T-score ni BMD bruto como predictor directo.

Estos algoritmos procesarán el vector de características multimodales para clasificar el riesgo del paciente, midiendo su capacidad de identificar interacciones complejas ausentes en el diagnóstico tradicional de DMO aislada.

3.5. Fase 4: Validación estadística e interpretabilidad

La partición de datos se realizará mediante un esquema *holdout* 80/20 estratificado **a nivel de paciente** (evitando la fuga de información entre exámenes de un mismo individuo). Dentro del conjunto de entrenamiento, se aplicará validación cruzada de 5 pliegues (*5-fold CV*) para la optimización de hiperparámetros.

Blindaje de la técnica SMOTE. La generación sintética de la clase minoritaria mediante SMOTE (§ 3.3) se ejecutará **exclusivamente dentro del ciclo de cada pliegue** de esta validación cruzada, ajustando el sobremuestreo únicamente sobre la partición de entrenamiento interna de cada *fold* (p. ej. mediante un `Pipeline` de *scikit-learn* que encapsule SMOTE junto al estimador). En ningún caso se aplicará SMOTE sobre el conjunto de entrenamiento completo antes de la partición en pliegues, ya que esto permitiría que observaciones sintéticas derivadas de un paciente aparecieran simultáneamente en el pliegue de entrenamiento y en el de validación de una misma iteración, constituyendo una fuga de información entre pliegues.

Validación de H (clasificación transversal): Se contrastará el Área Bajo la Curva (AUC-ROC) del mejor modelo de ML frente a los *baselines* clínicos ejecutables sobre los datos disponibles: T-score umbral, OST y regresión logística mínima (edad + sexo + IMC). Se utilizará la prueba no paramétrica pareada de DeLong [26] exigiendo un $p < 0,05$ para la comprobación de significancia en el $\Delta\text{AUC} \geq 0,05$.

Independencia estadística para la prueba de DeLong. Para garantizar la independencia estadística que exige el test pareado de DeLong, **todas** las evaluaciones sobre el conjunto de prueba oculto (*Test Set*) — tanto del comparador de línea base como de cada modelo de la escalera de complejidad — se realizarán utilizando exclusivamente **la visita más reciente de cada paciente**.

Este es un requisito matemático innegociable: la prueba de DeLong asume observaciones independientes entre las curvas ROC comparadas, y evaluar múltiples visitas del mismo paciente en el conjunto de prueba inflaría artificialmente el peso estadístico de los pacientes con más visitas, invalidando la prueba de hipótesis. Más allá del requisito estadístico, este enfoque es también **clínicamente más realista**: refleja el escenario de uso real de un modelo de apoyo diagnóstico, en el que se evalúa al paciente en su estado clínico actual, y elimina el ruido introducido por exámenes tempranos de pacientes longitudinales cuyo estado óseo en visitas antiguas ya no es representativo de su condición presente.

Criterios de éxito pre-especificados para H. La validación de H emplea dos criterios pre-especificados evaluados sobre el conjunto de prueba oculto. El criterio primario es $\Delta\text{AUC} \geq 0,05$ con significancia estadística de la prueba de DeLong ($p < 0,05$): dado que el comparador formal de línea base alcanzó un AUC de 0,883 (Tabla 4.4), los modelos avanzados de la Fase 3 deben alcanzar $\text{AUC} \geq 0,933$ para satisfacer este criterio. El criterio complementario es $\Delta\text{F1} \geq 0,10$ sobre el F1-score del comparador de línea base ($0,592 \rightarrow \text{objetivo} \geq 0,692$), métrica que refleja un mejor equilibrio entre precisión (0,454) y sensibilidad (0,852) bajo el desbalance de clases observado (15,6 % de prevalencia en el conjunto de prueba, $n_+ = 81$). **H se considerará respaldada si se satisface al menos uno** de los dos criterios ($\Delta\text{AUC} \geq 0,05$ con DeLong $p < 0,05$, o $\Delta\text{F1} \geq 0,10$ manteniendo AUC no inferior al comparador de línea base), evitando que la validación dependa exclusivamente de superar un techo de AUC ya de por sí elevado sin por ello diluir la falsabilidad de la hipótesis. Se declara como riesgo metodológico explícito que, cerca del techo de la escala AUC, los incrementos de 0,05 son progresivamente más difíciles de detectar con significancia estadística (*efecto techo*) y que el reducido número de positivos en el conjunto de prueba ($n_+ = 81$) limita la potencia de la prueba de DeLong para diferencias de esa magnitud; como mitigación, el AUC del modelo final se complementará con validación cruzada repetida o bootstrap para cuantificar la incertidumbre de la estimación puntual.

Finalmente, para dotar al sistema de transparencia clínica (OE3), se calcularán los valores SHAP (*SHapley Additive exPlanations*) [37]. Esto permitirá cuantificar la contribución marginal exacta de cada modalidad DXA (e.g., impacto de la masa magra frente a la geometría del cuello femoral) en la evaluación de riesgo de cada paciente. Se complementará con análisis de ablación multimodal secuencial: DMO solo $\rightarrow$ +Composición $\rightarrow$ +HSA $\rightarrow$ +Morfometría vertebral.

3.6. Cronograma de trabajo

El proyecto contempla una duración total de 18 meses, dividido en tres grandes fases semestrales:

- **Semestre 1 (2026):** Consolidación de la base de datos `prodigy.db`, ingeniería de características multimodales, manejo de desbalance (Cumplimiento de OE1) y revisión del marco teórico.
- **Semestre 2 (2026):** Entrenamiento, sintonización de hiperparámetros y *benchmarking* comparativo de la escalera de algoritmos transversales (Cumplimiento de OE2).
- **Semestre 1 (2027):** Evaluación exhaustiva mediante prueba de DeLong, extracción de interpretabilidad SHAP, análisis de ablación multimodal, redacción del documento final de tesis y defensa (Cumplimiento de OE3).

Capítulo 4

Resultados preliminares y análisis

Este capítulo documenta los avances realizados durante la fase preparatoria del proyecto, incluyendo la consolidación inicial de la base de datos CIMOHU, la auditoría de calidad de datos por modalidad DXA, y los resultados de un experimento piloto de clasificación de línea base. Estos resultados preliminares demuestran la viabilidad técnica del *pipeline* propuesto y establecen los referentes cuantitativos contra los cuales se medirán los modelos avanzados.

4.1. Estado de la consolidación de la base de datos (*ETL*)

La base de datos del CIMOHU se distribuye en 27 respaldos históricos en formato `.mdb` generados por el software de administración del densitómetro GE Lunar Prodigy entre 2009 y 2026. La Fase 1 de la metodología (§ 3.2) contempla la migración y unificación de estos respaldos hacia una base de datos relacional consolidada (`prodigy.db`).

Tabla 4.1: Estado de consolidación de los respaldos de la base de datos CIMOHU. †† Mediana calculada sobre los 1.497 intervalos entre visitas consecutivas de los 938 pacientes con ≥ 2 visitas; el promedio de esos mismos intervalos es de 0,94 años, sustancialmente mayor que la mediana por la cola larga de reexámenes espaciados varios años.

Métrica	Valor	Unidad
Respaldos <code>.mdb</code> identificados	27	archivos
Respaldos procesados y migrados	27	archivos (100 %)
Período cubierto	2009–2026	17 años
Registros totales de exámenes	9.426	exámenes DXA
Pacientes únicos identificados	3.240	adultos costarricenses
Pacientes con múltiples visitas (≥ 2)	938	pacientes
Intervalo mediano entre visitas ^{††}	0,31	años
Seguimiento máximo registrado	14,15	años

Los 27 respaldos han sido procesados y migrados exitosamente a la base de datos relacional `prodigy.db`. El proceso de migración incluyó la resolución de inconsistencias de codificación de caracteres, la estandarización de identificadores de paciente (`patient_id`), y la detección de registros duplicados por fecha de examen (<0,3 % de registros marcados para revisión manual).

4.2. Estadísticas descriptivas de la cohorte CIMOHU

La Figura 4.1 presenta la escala y composición de la base de datos consolidada. La base de datos incluye tanto exámenes de densitometría ósea (columna/cadera con T-score) como exámenes de composición corporal total sin evaluación densitométrica, lo que explica que la distribución por sexo de la cohorte etiquetada ($n = 2.591$) sea de 56,0 % mujeres y 44,0 % hombres, más equilibrada que la de un centro exclusivamente de osteoporosis, dado que el CIMOHU también realiza valoraciones de composición corporal para diversas indicaciones clínicas.




Figura 4.1: Escala y composición de la base de datos DXA del CIMOHU. Los porcentajes de cobertura se calculan sobre el total de 9.426 exámenes. Las modalidades HSA y VFA se activan selectivamente según la indicación clínica, lo que produce su menor cobertura. La subcohorte con múltiples visitas se deriva del conjunto completo de pacientes con dos o más visitas registradas.

De los 3.240 pacientes en `prodigy.db`, 2.591 (80,0 %) poseen al menos un examen de columna o cadera con T-score válido y constituyen la **cohorte etiquetada** del estudio. Los 649 pacientes restantes recibieron exclusivamente exámenes de composición corporal total u otras modalidades sin medición densitométrica, por lo que no pueden clasificarse bajo criterios OMS y quedan fuera del análisis de riesgo. Todas las estadísticas siguientes corresponden a esta cohorte etiquetada ($n = 2.591$), que es la base de datos sobre la que se entrenan y evalúan los modelos de aprendizaje automático.

La distribución de la variable objetivo (clasificación T-score por criterios OMS, peor T-score por paciente entre columna y cadera) en la cohorte etiquetada es: osteoporosis ($T\text{-score} \leq -2,5$): 15,9 %;

osteopenia ($-2,5 < \text{T-score} \leq -1,0$): 25,0 %; y estado normal: 59,1 %. Esta distribución refleja el desbalance de clases moderado que motiva la implementación de SMOTE en la Fase 2 de la metodología (§ 3.3).

La Tabla 4.2 resume las características demográficas y clínicas de la cohorte etiquetada. Los valores proceden de la **Fase 6 del notebook** `01_pilotos_osteoporosis.ipynb` (§ “Gap 4 — Reconstrucción de la Tabla 4.1”), que reemplaza al script `04_descriptive_stats.py` (no disponible en el repositorio actual); la fuente citable es ahora ese notebook. Se usa la primera visita de cada paciente para variables demográficas (edad, IMC, sexo) y el peor T-score a lo largo de todas las visitas para la clasificación diagnóstica.

Tabla 4.2: Características demográficas y clínicas de la cohorte etiquetada CIMOHU ($n = 2.591$). Fuente: Fase 6, `01_pilotos_osteoporosis.ipynb`. † Sólo pacientes con examen lumbar (site=0): $n = 1.024$. ‡ Sólo pacientes con examen de cadera (sites 1/2/3, mín. por paciente): $n = 2.588$. § Composición corporal (site=13, label=61): $n = 665$ pacientes; estadísticas a nivel paciente (media de visitas). Los valores de porcentaje de grasa y masa magra corresponden a esta subcohorte y difieren de los reportados en versiones anteriores del documento, que utilizaban un filtro de composición menos restrictivo.

Variable	Media $\pm$ DE	Rango
Edad (años)	41,4 $\pm$ 19,1	17,8 – 95,6
Índice de masa corporal (kg/m ²)	25,9 $\pm$ 4,7	14,9 – 57,6
T-score columna lumbar (L1–L4)†	−1,40 $\pm$ 1,57	véase nota ^a
T-score cadera (mínimo entre sitios)‡	−0,54 $\pm$ 1,67	véase nota ^a
Masa grasa total (%)§	29,2 $\pm$ 11,1	6,4 – 56,9
Masa magra total (kg)§	39,0 $\pm$ 9,6	9,3 – 71,7
<i>Distribución por sexo</i>		
Mujeres	1.450 (56,0 %)	
Hombres	1.141 (44,0 %)	
<i>Distribución por clase (variable objetivo)</i>		
Normal (T-score $> -1,0$)	1.530 (59,1 %)	
Osteopenia ($-2,5 < \text{T} \leq -1,0$)	648 (25,0 %)	
Osteoporosis ($\text{T} \leq -2,5$)	413 (15,9 %)	

4.3. Auditoría de calidad de datos por modalidad

La Tabla 4.3 presenta el porcentaje de datos faltantes por variable clave en cada modalidad. La evaluación fue realizada sobre los 9.426 exámenes consolidados en `prodigy.db`.

^{1a} La base de datos contiene valores de T-score extremos (lumbar: valores menores a $-7,9$; cadera: valores mayores a $+4,5$) que probablemente corresponden a artefactos de calibración o captura de datos; su rango no se reporta en la tabla para no distorsionar la lectura. La depuración sistemática de estos valores extremos se realiza en la Fase 1 del *pipeline* de la tesis, previo al entrenamiento de modelos.

Tabla 4.3: Auditoría de calidad de datos: porcentaje de datos faltantes por modalidad y variable, tras la corrección del filtro de composición corporal descrita en la Fase 1 (`site=13` y `label=61`, § 3.2).

Modalidad	Variable clave	% Disponible	% Faltante
DMO tabular	T-score lumbar (L1–L4)	99,1	0,9
	T-score cuello femoral	98,7	1,3
	T-score cadera total	97,4	2,6
Composición corporal	Masa grasa total (%) [*]	9,7	90,3
	Masa magra total (kg) [*]	9,7	90,3
	Zona android/gynoid	89,3	10,7
HSA	Área sección transversal (CSA)	16,2	83,8
	CSMI (cuello femoral)	16,2	83,8
	Ancho cortical	16,2	83,8
VFA	Alturas vertebrales (T6–L4)	26,5	73,5
	Grado deformidad (Genant)	26,5	73,5

* La cobertura de composición corporal de **cuerpo completo** es de 9,7 % de los 9.426 exámenes (918 exámenes válidos con `site=13` y `label=61`), equivalente a 665 de los 3.240 pacientes (20,5 %) a nivel de paciente. Esta cifra corregida sustituye a una estimación previa de 94,6 % que resultó de contar cualquier fila de `lunar__Composition` sin aplicar el filtro `site=13 AND label=61`; dado que dicha tabla almacena **una fila por región anatómica reportada y no una fila por examen** (cabeza, tronco, extremidades, zonas android/gynoid, además del total corporal), dicho conteo ingenuo sobreestimaba masivamente la disponibilidad real de composición de **cuerpo completo**, el único nivel de agregación clínicamente utilizable para el análisis de ablación (§ 3.3). Esta corrección es consistente con el hallazgo de cohortes casi disjuntas documentado en la Sección 4.5 y en el Marco Teórico (§ 2.1).

La auditoría revela un patrón de *missingness* no aleatorio (*missing not at random*, MNAR): las modalidades de composición de cuerpo completo, HSA y VFA tienen cobertura baja (9,7 %, 16,2 % y 26,5 %, respectivamente) porque son activadas selectivamente por el operador cuando existe una indicación clínica o deportiva/nutricional específica. Esto implica que los pacientes con estas modalidades tienden a diferir sistemáticamente —en indicación clínica y, en el caso de composición corporal, también en edad y estado de salud (§ 4.5)— de la cohorte etiquetada principal, lo que introduce un sesgo potencial de selección en cualquier análisis de ablación multimodal que las combine.

Esta característica del *dataset* justifica la estrategia de imputación múltiple por ecuaciones encadenadas (MICE) contemplada en la Fase 1 (§ 3.2) para las modalidades HSA y VFA, cuya *missingness* responde a un criterio clínico dentro de la misma población de referencia. La composición corporal de cuerpo completo, en cambio, **no** se trata mediante MICE dentro de la cohorte etiquetada, precisa-

mente porque su ausencia no es aleatoria respecto a la variable objetivo (los pacientes sin composición corporal son, en su mayoría, la cohorte clásica de osteoporosis) y una imputación masiva del ~ 90 % de los valores no aportaría señal real; en su lugar, se aborda mediante el modelo de ablación independiente descrito en la Fase 2 (§ 3.3) y evaluado en la Sección 4.5. Para el análisis de ablación (OE3) sobre HSA y VFA, se estratificarán los experimentos según la disponibilidad de modalidad.

4.4. Experimento piloto: regresión logística de línea base

Para establecer el referente de rendimiento mínimo (*baseline*) y verificar la presencia de señal predictiva en los datos CIMOHU, se realizó un experimento piloto de clasificación binaria (osteoporosis vs. no osteoporosis) utilizando regresión logística con variables tabulares básicas.

Configuración del experimento

El experimento se realizó sobre la cohorte etiquetada completa con datos demográficos completos ($n = 2.591$ pacientes con T-score válido de columna y/o cadera). La partición 80/20 se realizó estrictamente a nivel de paciente (agrupando por `pat_handle`, estratificando por la etiqueta a nivel paciente): 2.072 pacientes (3.004 visitas, 15,4 % osteoporosis) para entrenamiento y 519 pacientes (736 visitas, 16,0 % osteoporosis) para prueba, sin que ninguna visita de un mismo paciente cruzara entre ambos conjuntos, en estricto apego a los lineamientos de la Fase 4 (§ 3.5). SMOTE se aplicó exclusivamente sobre el conjunto de entrenamiento, dentro de un *pipeline* de *imbalanced-learn* que garantiza que el sobremuestreo sintético nunca contamina el conjunto de prueba.

Los *features* utilizados son las tres variables demográficas con cobertura del 100 % en la cohorte etiquetada: **edad, sexo e IMC**. Estos tres predictores son exactamente los que emplean las herramientas de cribado clínico convencionales (OST: edad + peso; ORAI: edad + peso + uso de estrógenos) y los que un médico conoce antes de ordenar cualquier estudio de imagen. Los T-scores y el BMD bruto fueron excluidos deliberadamente: la etiqueta de clasificación se deriva directamente del T-score, y el BMD es su precursor inmediato, por lo que incluirlos constituiría una fuga de información que inflaría artificialmente las métricas.

Nota sobre variables de composición corporal. La cohorte etiquetada ($n = 2.591$ pacientes con T-score) y la cohorte con escaneo de cuerpo completo ($n = 665$ pacientes) son casi mutuamente excluyentes: solo 42 pacientes coinciden en ambas. Incorporar masa grasa o masa magra en este piloto equivaldría a imputar ~ 98 % de los valores con la mediana de entrenamiento —una constante sin

información discriminativa—, por lo que estas variables se excluyen del comparador de línea base. El aporte predictivo real de la composición corporal se documenta de forma aislada, mediante un modelo de ablación de regresión sobre la intersección real de 42 pacientes, en la Sección 4.5 (Piloto B’).

Evaluación sobre visita más reciente por paciente. A diferencia de una evaluación piloto exploratoria basada en exámenes agregados, las métricas reportadas a continuación se calculan aplicando desde el inicio el protocolo de independencia estadística de la Fase 4 (§ 3.5): del conjunto de prueba de 519 pacientes se toma **una única visita por paciente, la más reciente**, antes de calcular cualquier métrica. Este es el mismo criterio que se aplicará a los modelos avanzados en la validación formal de H, lo que hace de este piloto un baseline directamente comparable y libre de *data leakage* temporal.

Este experimento piloto es el comparador formal de H: la *regresión logística mínima* (*edad + sexo + IMC*) definida en OE2, reproducible sin equipamiento DXA y equivalente en complejidad informacional a las calculadoras clínicas OST y ORAI.

Resultados

Tabla 4.4: Resultados del experimento piloto de regresión logística (clasificación binaria: osteoporosis vs. no osteoporosis), evaluados sobre el conjunto de prueba independiente (1 visita/paciente, la más reciente). IC 95 % obtenidos por bootstrap de la evaluación ($B = 5.000$, semilla fija); el modelo no se reentrenó en ninguna iteración.

Métrica	Valor puntual	IC 95 % bootstrap
AUC-ROC	0,883	[0,844 – 0,918]
Sensibilidad (recall)	0,852	[0,773 – 0,926]
Especificidad	0,811	[0,772 – 0,847]
Precisión	0,454	[0,374 – 0,533]
F1-score	0,592	[0,515 – 0,664]
Tamaño conjunto de prueba	519 pacientes (81 con osteoporosis)	

El modelo logístico piloto (comparador formal de H: edad + sexo + IMC) obtiene un AUC de 0,883, un resultado considerablemente más alto que las estimaciones preliminares obtenidas con protocolos de evaluación menos estrictos. Este aumento en el AUC no es una casualidad estadística: refleja un *baseline* metodológicamente pulcro, **libre de *data leakage***, obtenido al aislar la visita más reciente de cada paciente en el conjunto de prueba. En esa visita —típicamente la de mayor edad y con el estado clínico más consolidado del paciente— la edad y el IMC separan las clases (osteoporosis vs. no osteoporosis) de forma sustancialmente más clara que en visitas tempranas, cuyo ruido diluía artificialmente la señal demográfica en evaluaciones previas menos rigurosas. Este valor supera ampliamente los reportados en

la literatura para herramientas de cribado simples —OST ($AUC \approx 0,71$) y ORAI ($AUC \approx 0,74$) sobre otras cohortes [13]— y también al comparador externo de referencia regional (Vega et al. [19], $AUC = 0,81$), lo que valida que la información demográfica por sí sola, evaluada con rigor metodológico, ofrece ya una discriminación muy alta en esta cohorte.

La precisión (0,454) y el F1-score (0,592) reflejan el desbalance de clases inherente al problema (15,6 % de osteoporosis en el conjunto de prueba independiente, 81/519; nótese que este porcentaje difiere levemente del 16,0 % reportado para las 736 visitas del conjunto de prueba antes de restringir a la visita más reciente por paciente): con un umbral de decisión por defecto (0,5), el modelo prioriza la sensibilidad (0,852) sobre la precisión, generando un número relativamente alto de falsos positivos frente a los verdaderos positivos. Esto es clínicamente razonable para un instrumento de cribado —donde el costo de un falso negativo (osteoporosis no detectada) es mayor que el de un falso positivo (derivación innecesaria a DXA de confirmación)—, pero también señala el margen de mejora que deben capturar los modelos multimodales avanzados de la Fase 3, discutido en la Sección 4.6.

Este resultado eleva sustancialmente el piso de comparación de H: el límite superior del IC 95 % bootstrap del AUC del comparador (0,918) se sitúa aun por debajo del umbral de 0,933 que los modelos avanzados deben alcanzar para cumplir $\Delta AUC \geq 0,05$, lo que confirma que el objetivo sigue siendo distinguible del nivel base con la incertidumbre ahora cuantificada. Las implicaciones completas —umbral 0,933, criterio F1 complementario y riesgo de efecto techo— se detallan en la Fase 4 (§ 3.5).

Variables más relevantes (importancia de características)

Las tres variables con mayor coeficiente absoluto en el modelo logístico piloto fueron (en orden descendente): (1) edad, (2) IMC, y (3) sexo. El efecto de la edad es el predictor dominante, consistente con la fisiopatología de la osteoporosis postmenopáusica y senil; el IMC refleja el efecto protector de la carga mecánica sobre la densidad ósea; y el sexo captura la mayor prevalencia en mujeres (§ 4.2).

4.5. Análisis de ablación de rescate: aporte de la composición corporal (Piloto B')

El diseño original del Piloto B (§ 3.3) contemplaba un segundo modelo de clasificación, entrenado sobre la submuestra de cuerpo completo, para aislar el aporte del tejido blando (masa grasa y masa magra) sobre el riesgo de osteoporosis. La ejecución de este piloto expuso el hallazgo más crítico de

la fase de auditoría de datos: al construir la intersección real a nivel de paciente entre la cohorte con T-score válido ($n = 2.591$) y la cohorte con composición corporal de cuerpo completo ($n = 665$), solo **42 pacientes** coinciden en ambas modalidades, y **ninguno de esos 42 pacientes presenta osteoporosis** (T-score peor observado = $-2,10$, por encima del umbral OMS de $-2,5$; media = $0,47$; máximo = $4,36$).

Esta cohorte de una sola clase hace que la clasificación binaria sea **matemáticamente inviable** sobre la intersección real: AUC-ROC, sensibilidad y especificidad quedan indefinidos cuando no existe variabilidad en la variable objetivo. Lejos de ser una limitación que invalida el análisis, este resultado es en sí mismo un **hallazgo de auditoría**: confirma cuantitativamente el sesgo demográfico ya documentado en el Capítulo 2 (§ 2.1) — los pacientes derivados a composición corporal de cuerpo completo en el CIMOHU son sistemáticamente más jóvenes y sanos que la cohorte clásica de referencia para osteoporosis.

Reformulación como regresión sobre el T-score continuo. Siguiendo el ajuste metodológico descrito en la Fase 2 (§ 3.3), la pregunta científica original —¿cuánto poder predictivo aporta el tejido blando frente a las variables demográficas puras?— se evalúa mediante regresión lineal sobre el T-score continuo (`tscore_min`), usando Validación Cruzada Leave-One-Out (LOOCV) dado el tamaño muestral reducido ($n = 42$). Se comparan dos modelos anidados por R^2 promedio fuera de muestra: uno con solo las tres variables demográficas (edad, sexo, IMC) y otro que añade las variables de composición corporal (masa grasa, masa magra y porcentaje de grasa corporal).

Tabla 4.5: Análisis de ablación de rescate (Piloto B’): regresión LOOCV sobre el T-score continuo, intersección real CIMOHU ($n = 42$ pacientes).

Modelo	R^2 (LOOCV)	MAE (LOOCV)
Solo demografía (edad, sexo, IMC)	0,124	0,950
Demografía + composición corporal (grasa, magra, % grasa)	0,381	0,745

El hallazgo empírico central de este capítulo. Las variables puramente demográficas explican apenas el 12,4 % de la varianza del T-score ($R^2 = 0,124$). Al introducir las tres variables de composición corporal, el poder predictivo se **triplica** a un 38,1 % ($R^2 = 0,381$), con una reducción concomitante del error absoluto medio (de 0,950 a 0,745 desviaciones estándar de T-score). Este resultado se obtiene incluso en una sub-cohorte de apenas 42 pacientes sistemáticamente más jóvenes y sanos que la población clínica de referencia —la condición menos favorable posible para observar una asociación entre tejido blando y densidad ósea—, lo que refuerza la robustez de la señal encontrada.

Para cuantificar la solidez estadística de este resultado, se realizó en la Fase 6 del notebook (01_pilotos_osteoporosis.ipynb) una **prueba de Wilcoxon signed-rank pareada** sobre los errores absolutos LOO por paciente (prueba no paramétrica, apropiada para $n = 42$), junto con un **IC 95 % bootstrap** del $\Delta R^2 = R^2_{full} - R^2_{demo}$ ($B = 5.000$ remuestreos). Los resultados son: $W = 601,0$, $p = 0,031$ (hipótesis alternativa: el modelo con composición corporal reduce sistemáticamente los errores absolutos); IC 95 % bootstrap de $\Delta R^2 = 0,257$: $[-0,134, 0,556]$.

El test de Wilcoxon alcanza significancia estadística al nivel $\alpha = 0,05$, indicando que la reducción de error es sistemática y no atribuible únicamente al azar muestral. No obstante, el IC 95 % bootstrap de ΔR^2 incluye cero, lo que refleja alta incertidumbre sobre la *magnitud* del R^2 mejorado dado el tamaño muestral reducido. Adicionalmente, la multicolinealidad entre las variables de composición corporal es **severa** (VIF cuantificados en la misma Fase 6: porcentaje de grasa corporal VIF = 83,3; masa grasa VIF = 41,3; masa magra VIF = 25,6; variables demográficas: VIF < 5), lo que puede inflar el R^2 observado del modelo ampliado. Por estas razones, este resultado se reporta como **hallazgo exploratorio con evidencia preliminar de significancia estadística** del Piloto B', no como confirmación definitiva del poder predictivo de la composición corporal.

Con esa salvedad, el patrón observado (R^2 casi tres veces mayor al incorporar composición corporal) es **compatible con** y motiva, con datos propios del CIMOHU, la integración multimodal (DMO + composición corporal) prevista en el marco teórico (§ 2.1) y en el diseño de ablación de la Fase 2 de la metodología: es un indicio preliminar de que el tejido blando podría aportar información sobre la densidad ósea que las variables demográficas, por sí solas, no capturan, hipótesis que la Fase 3 deberá confirmar sobre una muestra de mayor tamaño y con los controles estadísticos apropiados (regularización, prueba de significancia de la mejora de ajuste).

4.6. Discusión de los resultados preliminares

Los resultados preliminares demuestran la viabilidad técnica del proyecto en cuatro dimensiones:

1. **Viabilidad de los datos:** La consolidación exitosa de los 27 respaldos .mdb y la disponibilidad de 9.426 exámenes de 3.231 pacientes adultos costarricenses con examen registrado (3.240 en la base de datos) confirman que el activo de datos es suficiente para la magnitud del análisis propuesto. La subcohorte de 938 pacientes con múltiples visitas, con seguimiento máximo de 14,15 años, es inédita en el contexto centroamericano.

2. **Viabilidad del *pipeline* técnico:** La migración, limpieza y auditoría de datos reveló un *dataset* de calidad alta en la modalidad principal de DMO ($> 97\%$ de cobertura de T-score), con un patrón de datos faltantes conocido y tratable (MICE) en las modalidades de menor cobertura (HSA con $16,2\%$; VFA con $26,5\%$). La composición corporal de cuerpo completo, con solo el $20,5\%$ de cobertura a nivel de paciente (665/3.240; Tabla 4.3), no se imputa masivamente sino que se aborda mediante el modelo de ablación independiente de la Fase 2.
3. **Viabilidad de la hipótesis H, con un piso más alto de lo previsto:** El comparador formal H —regresión logística mínima (edad + sexo + IMC), idéntico en información a las calculadoras OST y ORAI, evaluado con el protocolo riguroso de independencia estadística (1 visita/paciente, la más reciente)— alcanzó en la cohorte CIMOHU un AUC de 0,883, superando no solo a OST (0,71) y ORAI (0,74), sino también al mejor comparador clínico publicado para la región latinoamericana (Vega et al. [19], $AUC = 0,81$). Este resultado confirma que el *dataset* CIMOHU contiene señal predictiva genuina y, como se detalla en la Fase 4 (§ 3.5), eleva sustancialmente el piso de comparación exigido a los modelos multimodales de la Fase 3.
4. **Indicio empírico propio, exploratorio con evidencia preliminar de significancia, a favor de la integración multimodal:** El análisis de ablación de rescate (Piloto B', § 4.5) muestra que añadir composición corporal a las variables demográficas casi triplica el poder explicativo observado sobre el T-score (R^2 LOO de 0,124 a 0,381; $\Delta R^2 = 0,257$). La reducción de error es estadísticamente significativa según la prueba de Wilcoxon pareada ($W = 601$, $p = 0,031$, $n = 42$), aunque el IC 95% bootstrap de ΔR^2 incluye cero ($[-0,134, 0,556]$), lo que indica alta incertidumbre sobre la magnitud. La multicolinealidad severa entre las variables de composición (VIF: 83,3 / 41,3 / 25,6) requiere regularización en la Fase 3. Con esas salvedades, el patrón —observado en la sub-cohorte menos favorable posible, compuesta por pacientes jóvenes y sanos— motiva la confirmación rigurosa de la integración multimodal en la Fase 3 sobre una muestra de mayor tamaño.

Bibliografía

- [1] O. Johnell y J.A. Kanis. «An estimate of the worldwide prevalence and disability associated with osteoporotic fractures». En: *Osteoporosis International* 17.12 (2006), págs. 1726-1733. DOI: 10.1007/s00198-006-0172-4.
- [2] J.A. Kanis et al. «European guidance for the diagnosis and management of osteoporosis in postmenopausal women». En: *Osteoporosis International* 30 (2019), págs. 3-44. DOI: 10.1007/s00198-018-4704-5.
- [3] S. Cerdas-Pérez et al. «Epidemiology of hip fractures in Costa Rica and development of country-specific thresholds to estimate fracture risk». En: *Archives of Osteoporosis* 21.1 (2026), pág. 30. DOI: 10.1007/s11657-026-01659-z.
- [4] A. Medina et al. «Epidemiological data and burden of osteoporosis and fragility fractures in Latin America: changes over a decade». En: *Revista Colombiana de Reumatología* 32.3 (2025), págs. 247-254. DOI: 10.1016/j.rcreu.2024.11.002.
- [5] Instituto Nacional de Estadística y Censos (INEC). *Proyecciones Nacionales de Población 2022–2070*. Proyecciones demográficas que estiman que el 25 % de la población de Costa Rica superará los 65 años para 2050. San José, Costa Rica, 2024. URL: <https://www.inec.cr/poblacion/estimaciones-y-proyecciones-de-poblacion>.
- [6] S. Castro-Gamboa et al. «Factores de riesgo y prevalencia de osteopenia y osteoporosis en mujeres posmenopáusicas diagnosticadas por densitometría ósea». En: *Acta Médica Costarricense* 64.1 (2022), págs. 44-51. DOI: 10.51481/amc.v64i1.1217.
- [7] S.M. Burnett-Bowie et al. «The American Society for Bone and Mineral Research Task Force on clinical algorithms for fracture risk report». En: *Journal of Bone and Mineral Research* (2024). DOI: 10.1093/jbmr/zjae048.
- [8] J. Moncada-Jiménez et al. «Exploring Handgrip Strength as a Cross-cultural Correlate of Body Composition and Upper Body Strength in Older Adults from Costa Rica and Kansas». En: *Journal of Cross-Cultural Gerontology* 38 (2023), págs. 223-244. DOI: 10.1007/s10823-023-09481-7.

- [9] J.A. Kanis et al. «FRAX and the assessment of fracture probability in men and women from the UK». En: *Osteoporosis International* 19 (2008), págs. 385-397. DOI: 10.1007/s00198-007-0543-5.
- [10] World Health Organization. *Assessment of fracture risk and its application to screening for postmenopausal osteoporosis*. Inf. téc. WHO Technical Report Series 843. Geneva: World Health Organization, 1994.
- [11] A. Aibar-Almazán et al. «Current status of the diagnosis and management of osteoporosis». En: *International Journal of Molecular Sciences* 23.16 (2022), pág. 9465. DOI: 10.3390/ijms23169465.
- [12] T.K. Yoo et al. «Osteoporosis risk prediction for bone mineral density assessment of postmenopausal women using machine learning». En: *Yonsei Medical Journal* 54.6 (2013), págs. 1321-1330. DOI: 10.3349/ymj.2013.54.6.1321.
- [13] M. Je et al. «Development and evaluation of a machine learning model for osteoporosis risk prediction in Korean women». En: *BMC Women's Health* 25 (2025), pág. 146. DOI: 10.1186/s12905-025-03669-4.
- [14] W. Jin et al. «Development and validation of explainable machine learning models for female hip osteoporosis using electronic health records». En: *International Journal of Medical Informatics* 199 (2025), pág. 105889. DOI: 10.1016/j.ijmedinf.2025.105889.
- [15] A. Carvalho y P.J. Gavaia. «Stacking ensemble machine learning for osteoporosis prediction from routine clinical data». En: *Bone* (2025). DOI requires verification; article in press at time of submission.
- [16] F. Rahim et al. «Machine learning algorithms for diagnosis of hip bone osteoporosis: a systematic review and meta-analysis». En: *BioMedical Engineering OnLine* 22 (2023), pág. 68. DOI: 10.1186/s12938-023-01132-9.
- [17] Y. Wu et al. «Predictive value of machine learning for fracture risk: a systematic review and meta-analysis». En: *BMJ Open* 14.1 (2023), e071430. DOI: 10.1136/bmjopen-2022-071430.
- [18] D. Miranda et al. «Selection of Bone fragility-Related Features Obtained with Bi-Directional Axial Transmission, Through a Machine Learning Strategy». En: *IEEE Latin American Ultrasonics Symposium (LAUS)*. 2021.

- [19] E. Vega et al. *Assessing fracture probability in patients with different types of fractures using a pre-trained ANN model trained with demographic, anthropometric, and densitometric (DXA) characteristics*. Abstract presentado en: American Society for Bone and Mineral Research Annual Meeting (ASBMR 2024), Toronto, Canadá. Publicado en: *Journal of Bone and Mineral Research*, suplemento de congreso. Datos confirmados vía SIGEVA-CONICET (bicyt.conicet.gov.ar/fichas/produccion/117969) n=478 mujeres posmenopáusicas, AUC=0,81±0,03, ANN-MLP, 12 variables DXA. Sin DOI, volumen ni páginas disponibles. 2024.
- [20] G.A. Albuquerque, D.D.A. Carvalho, A.S. Cruz et al. «Osteoporosis screening using machine learning and electromagnetic waves». En: *Scientific Reports* 13 (2023), pág. 12865. DOI: 10.1038/s41598-023-40104-w.
- [21] D. Hussain et al. «DXA femur image segmentation using FCNN». En: *Diagnostics* 14 (2024), pág. 1328. DOI: 10.3390/diagnostics14131328.
- [22] W. Ong et al. «Artificial Intelligence Applications for Osteoporosis Classification Using Computed Tomography». En: *Bioengineering* 10.12 (2023), pág. 1364. DOI: 10.3390/bioengineering10121364.
- [23] A. Conforti et al. «Artificial Intelligence and Machine Learning in the Diagnosis and Management of Osteoporosis: A Comprehensive Review». En: *Medicina* 62.1 (2026), pág. 27. DOI: 10.3390/medicina62010027.
- [24] J. Tang et al. «Fusion of X-Ray Images and Clinical Data for a Multimodal Deep Learning Prediction Model of Osteoporosis: Algorithm Development and Validation Study». En: *JMIR Medical Informatics* 13 (2025). Co-primer autores: Tang J. y Yin X. Wu D. es autor correspondiente. n=1.780 pacientes, Chongqing Daping Hospital, China., e70738. DOI: 10.2196/70738.
- [25] F. Montiel-Ojeda, S. Cerdas-Pérez, P. Clark et al. «Dietary calcium intake in adults from Costa Rica and Panama». En: *Nutrición Hospitalaria* 40 (2023), págs. 576-583.
- [26] E.R. DeLong, D.M. DeLong y D.L. Clarke-Pearson. «Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach». En: *Biometrics* 44.3 (1988), págs. 837-845. DOI: 10.2307/2531595.
- [27] T.J. Beck et al. «Predicting femoral neck strength from bone mineral data: a structural approach». En: *Investigative Radiology* 25.1 (1990), págs. 6-18. DOI: 10.1097/00004424-199001000-00004.

- [28] A.M. Rathbun et al. «Differences in Geometric Strength at the Contralateral Hip between Men with Hip Fracture and Non-Fractured Comparators». En: *Bone* 132 (2020), pág. 115187. DOI: 10.1016/j.bone.2019.115187.
- [29] A.M. Rathbun et al. «Difference in the Trajectory of Change in Bone Geometry as Measured by Hip Structural Analysis in the Narrow Neck, Intertrochanteric Region, and Femoral Shaft between Men and Women Following Hip Fracture». En: *Bone* 92 (2016), págs. 124-131. DOI: 10.1016/j.bone.2016.08.020.
- [30] A.M. Rathbun et al. «Older men who sustain a hip fracture experience greater declines in bone mineral density at the contralateral hip than non-fractured comparators». En: *Osteoporosis International* 29.2 (2018), págs. 365-373. DOI: 10.1007/s00198-017-4280-0.
- [31] H.K. Genant et al. «Vertebral fracture assessment using a semiquantitative technique». En: *Journal of Bone and Mineral Research* 8.9 (1993), págs. 1137-1148. DOI: 10.1002/jbmr.5650080915.
- [32] B. Kirk, J. Zanker y G. Duque. «Osteosarcopenia: epidemiology, diagnosis, and treatment—facts and numbers». En: *Journal of Cachexia, Sarcopenia and Muscle* 11.3 (2020), págs. 609-618. DOI: 10.1002/jcsm.12567.
- [33] K.K. Oursler et al. «Short Communication: Low Muscle Mass Is Associated With Osteoporosis in Older Adults Living With HIV». En: *AIDS Research and Human Retroviruses* 36.4 (2020). Corrección 5-Jul-2026: journal, volumen, páginas y DOI corregidos según PubMed PMID:31762303, págs. 300-302. DOI: 10.1089/AID.2019.0207.
- [34] I. Barrientos-Calvo y E. Picado-Ovares. «Prevalencia de sarcopenia en población adulta mayor en Costa Rica». En: *Acta Médica Costarricense* 63.2 (2021), págs. 122-130. DOI: 10.51481/amc.v63i2.1121.
- [35] M.H. Edwards et al. «Osteoporosis and sarcopenia in older age». En: *Bone* 80 (2015), págs. 126-130. DOI: 10.1016/j.bone.2015.04.016.
- [36] N.V. Chawla et al. «SMOTE: Synthetic minority over-sampling technique». En: *Journal of Artificial Intelligence Research* 16 (2002), págs. 321-357. DOI: 10.1613/jair.953.
- [37] S.M. Lundberg y S.-I. Lee. «A unified approach to interpreting model predictions». En: *Advances in Neural Information Processing Systems* 30 (2017), págs. 4765-4774.

- [38] Centro de Investigación en Movimiento Humano, Universidad de Costa Rica. *Base de datos longitudinal de densitometría ósea DXA del CIMOHU*. Base de datos institucional, 2009–2026. 9.426 exámenes DXA de 3.231 pacientes adultos costarricenses con examen registrado (3.240 en la base de datos). Acceso restringido sujeto a aprobación del Comité Ético Científico de la UCR. 2026.
- [39] Y. Chacón-Araya, E. Carpio-Rivera y J. Moncada-Jiménez. «Changes in dual energy X-ray absorptiometry body composition scores in females following exercise-induced body fluid redistribution». En: *AUC Kinanthropologica* 60.1 (2024), págs. 49-65. DOI: 10.14712/23366052.2024.4.

Apendice

Apendice A

Clasificación de métodos de predicción

La siguiente tabla ilustra los métodos de aprendizaje automático revisados en la literatura, clasificados según el **tipo de datos de entrada** —Datos Clínicos Tabulares frente a Imágenes/Radiómica (CT/DXA)— para la **clasificación transversal del riesgo de osteoporosis**. Esta clasificación justifica la escalera de algoritmos propuesta en el Capítulo 3 y evidencia que el enfoque multimodal de *DeepDXA* atiende la brecha de integración multimodal menos explorada en el estado del arte latinoamericano.

Tabla A.1: Clasificación de la literatura principal de clasificación transversal de osteoporosis según el tipo de datos de entrada.

Objetivo clínico	Datos clínicos / Tabulares	Imágenes (CT/DXA) / Radiómica
Clasificación transversal (Normal vs. Osteoporosis)	<i>Random Forest / XGBoost / SVM</i> Carvalho & Gavaia [15] Je et al. [13] Jin et al. [14] Yoo et al. [12] Miranda et al. [18] <i>(SVM / BDAT ultrasonido, Chile)</i>	<i>CNN / Deep Learning</i> Ong et al. [22] Rahim et al. [16]

Apendice B

Distribución temporal de la literatura profesional

Los siguientes gráficos describen la distribución temporal de la literatura académica y profesional revisada para la construcción de esta propuesta.

La Figura B.1 evidencia un crecimiento sostenido en las publicaciones directamente relacionadas con la aplicación de Aprendizaje Automático y *Deep Learning* para la salud musculoesquelética y la densitometría ósea. Las publicaciones de la era XGBoost/DL (2018 en adelante, barra azul oscuro) concentran más del **75 %** de la bibliografía revisada (37 de 49 referencias), lo que confirma la vigencia y la alta actividad investigativa del tema propuesto.




Figura B.1: Distribución anual de la literatura profesional revisada relacionada con Aprendizaje Automático, DXA y Osteoporosis. Las barras azul oscuro corresponden a la era *Deep Learning* / XGBoost (2018–2026).